



面向大模型 RAG 推理场景 噪音文档的鲁棒性推理方法

NLP 实验四 · 题目 8 · 终期实验报告

队长姓名：刘忻洁 队长学号：202300180116

队员姓名：苗怀睿 队员学号：202300300079

2026 年 6 月 26 日

目录

1	研究问题与项目定位	2
1.1	题目要求	2
1.2	核心问题	2
1.3	核心发现摘要	2
2	数据准备与标准格式	3
2.1	原始数据	3
2.2	文档池定义	3
2.3	NoiserBench 数据集	4
2.4	后期扩展数据集	4
2.5	自建数据构建引擎	5
3	系统设计	7
3.1	总体架构	7
3.2	调用流水线	7
3.3	模块组织	8
4	方法设计	8
4.1	噪音注入机制	8
4.2	矫正方法	9
4.3	深化方法详解	9
5	评估指标设计	10
5.1	基础问答指标	10
5.2	自主鲁棒性指标	10
6	实验结果	10
6.1	实验一：噪音影响分析	11
6.1.1	主矩阵 (zh/main)	11
6.1.2	反事实数据集 (zh/fact)	12
6.1.3	噪音位置效应	13
6.1.4	跨语言对比	14
6.2	实验二：矫正方法对比	15
6.2.1	主实验 (zh/main, semantic)	15
6.2.2	反事实数据集验证 (zh/fact, counterfactual)	15
6.3	实验三：案例深度分析	16
6.3.1	zh/main 与 zh/fact 对比	16
6.3.2	英文案例研究 (en/main)	17

6.4	实验四：互锁效应——方法 $\times$ 噪音类型交互	17
6.4.1	核心实验： $r=0.75$ 互锁矩阵 (zh)	17
6.4.2	$r=0.5$ 对照与排名稳定性	19
6.4.3	英文互锁验证 (en/main)	20
6.5	实验五：深化实验	20
6.5.1	Confidence 消融实验	20
6.5.2	语义级 ISR/NAR	21
6.5.3	自适应矫正器	21
6.5.4	迭代自纠正	22
7	后期实验：跨数据集验证	22
7.1	实验设置	23
7.2	2WikiMultihopQA (英文多跳, $n = 500$)	23
7.2.1	实验一：噪音影响	23
7.2.2	实验二：矫正方法对比	24
7.2.3	反事实子集 (fact, $n = 500$)	25
7.3	MobileMem (中文 OCR 记忆 RAG, calc 子集, $n = 50$)	25
7.4	CmedqaRetrieval (中文医学, $n = 3999$)	28
7.5	跨数据集 Judge 梯度对比	29
7.6	后期实验小结	30
8	系统实现与前端演示	31
8.1	后端接口	31
8.2	前端界面	31
9	当前进度	33
10	与现有方法的比较	34
11	运行方式	34
12	总结	35

摘要

本项目研究大模型 RAG（检索增强生成）场景中，检索文档噪音对推理质量的影响及矫正方法。基于 RGB 数据集和 DeepSeek-chat 模型，系统实现了噪音比例、类型（语义噪音/反事实噪音/混合噪音）和位置四维度的控制实验，设计了 12 种矫正方法和 5 个自主鲁棒性评估指标（NS/NRS/ISR/NAR/CRR）。核心发现为“互锁效应”：CoT 证据链在语义噪音下最优（ $F1=0.791$ ），但在反事实噪音下反而有害（ $F1=0.708$ ，低于基线）；简单提示词指令在反事实噪音下逆袭为最优（ $F1=0.781$ ）。据此提出自适应矫正器，通过噪音类型检测自动路由到最优方法。后期在 2WikiMultihopQA、CmedqaRetrieval、MobileMem 等 8 类扩展数据集上验证了方法的跨域可迁移性，并补充 Judge 驱动的跨数据集鲁棒性对比。

1 研究问题与项目定位

1.1 题目要求

本项目对应 NLP 实验四题目 8：**面向大模型 RAG 推理场景噪音文档的鲁棒性推理方法**。题目要求关注大模型 RAG 场景中，检索结果可能包含与问题语义相关、但缺少逻辑依赖或会误导答案的上下文文档，进而影响模型问答准确率。项目需要完成以下任务：

- 探究上下文文档对模型问答性能的影响；
- 提出可量化的评估指标；
- 针对具体数据集给出实验结果、结论与分析；
- 结合具体案例分析不同文档对答案的影响；
- 设计矫正机制，例如提示词优化、迭代式生成等；
- 与现有方法进行性能比较，说明方法有效性与局限。

1.2 核心问题

本项目将问题形式化为：给定问题 q 、候选文档集合 $D = \{d_1, \dots, d_n\}$ 和参考答案 a ，当 D 中混入不同类型、比例和位置的噪音文档时，大模型生成答案 $\hat{a}$ 的准确率、证据来源和噪音采纳程度如何变化？此外，不同的矫正机制在不同噪音类型下表现如何？是否存在“互锁效应”——即最优方法取决于噪音类型。

1.3 核心发现摘要

经过完整的系统实现和 $n=50$ 级别的实验验证，本项目核心发现包括：

- **U 型抗噪 + 断崖效应**: LLM 在 0–75% 噪音下性能几乎不变, 但 positive 文档完全消失 ($r=1.0$) 时性能崩溃;
- **互锁效应**: CoT 证据链在语义噪音下最优 ($F1=0.791$), 但在反事实噪音下跌至 0.708 (比 naive 还差); 而简单 prompt 指令在反事实噪音下逆袭为最优 ($F1=0.781$);
- **位置效应**: 在 $r=0.75$ 反事实噪音下, 文档放末尾 (back) 的破坏力最大 ($F1=0.629$), 印证 recency bias 在错误信息场景下的危害;
- **跨语言一致性**: 英文 baseline (0.620) 显著低于中文 (0.768), 但 U 型抗噪模式跨语言一致;
- **方法深化**: 自适应矫正器、语义级 ISR/NAR、消融实验和迭代自纠正循环四项深化工作已实现并验证。

2 数据准备与标准格式

2.1 原始数据

项目初期使用 RGB 数据集作为公开问答与候选文档来源, 包含中英文主数据、反事实数据、信息整合数据和 refine 数据:

表 1: RGB 数据文件与用途

数据文件	语言	样本数	用途
zh.json, en.json	中/英	各 300	主问答数据, 含 positive 与 negative 文档池
zh_fact.json, en_fact.json	中/英	各 100	反事实噪音数据, 额外含 positive_wrong 和 fakeanswer
zh_int.json, en_int.json	中/英	各 100	信息整合类问题, 用于后续跨文档推理扩展
zh_refine.json, en_refine.json	中/英	各 300	refine 变体, 用于后续泛化验证

2.2 文档池定义

RGB 数据天然给出了适合本题的三类文档池:

表 2: 三类文档池与噪音含义

字段	实验含义	使用方式
positive	支持正确答案的有效文档	构造 clean RAG 上下文，计算 ISR
negative	语义相关但不能支持答案的普通噪音文档	模拟检索噪音，计算 NAR
positive_wrong	表面相关但指向错误答案的反事实文档	模拟更强误导性噪音，测试矫正机制

2.3 NoiserBench 数据集

项目额外引入 NoiserBench (ACL 2025) 作为补充评测数据集，提供七类预标注噪音 (semantic、cause_effect、counterfactual_answer 等)，与 RGB 自建的 semantic/counterfactual 注入机制互补。NoiserBench 涵盖三类推理跳数：

表 3: NoiserBench 子集概览

类别	子集	特点
Single-hop	NQ, RGB	单跳检索问题，标注语义噪音与反事实噪音
Multi-hop (explicit)	HotpotQA, 2WikiMQA, Bamboogle	多跳显式推理
Multi-hop (implicit)	StrategyQA, TempQA	多跳隐式推理 (常识/时间)
Mix-hop	PriorQA	混合跳数，测试模型的推理泛化能力

数据统一转换为 RGBRecord 格式，与现有实验流水线完全兼容。

2.4 后期扩展数据集

在中期 RGB 基线之外，项目通过 `scripts/prepare_*.py` 接入了 7 类公开/自建数据集，用于验证互锁效应与矫正方法的可迁移性：

表 4: 后期扩展数据集概览

数据集	语言	main 规模	实验规模	特点
2WikiMultihopQA	en	5000	n=500	多跳 Wikipedia, 同 context hard neg
CmedqaRetrieval	zh	3999	n=3999	中文医学 检索, 长 答案
MIRIAD-5.8M	en	5.8M	n=100	英文医学 长生成
MobileMem	zh	120×2	n=50	购物截图 OCR 记忆 图谱 RAG
BRIGHT / TEMPO / MultiHop-RAG	en	749–2255	sanity n=100	长文 hard neg / 论 坛 / 新闻 证据链
NoiserBench	en	子集各异	试跑 n=2	ACL'25 七类预标 注噪音

各数据集均提供 **main** 子集; 2Wiki、Cmedqa、BRIGHT 等另含 **fact** 子集 (脚本自动构造 **positive_wrong**), 用于 counterfactual 实验。MobileMem 分为 **calc** (多事件聚合计算) 与 **noncalc** (检索 QA) 两类子集。

2.5 自建数据构建引擎

由于公开数据集的规模有限, 且问题对于现有大模型过于简单, 为扩展数据覆盖面、验证方法的真实表现, 项目设计了一套基于文档爬取和 deepseek 生成的数据引擎。引擎支持从任意关键词出发, 全自动生成符合 RGB 格式的高质量 RAG 鲁棒性测试数据。




图 1: 数据构建引擎流程图

构建流程分为五个阶段：

- 关键词输入**：用户在前端输入主题关键词（如”量子力学””基因编辑”）；
- 文档爬取**：多策略搜索中文维基百科 API，扩展关键词变体（原词、分词、”原理”、”历史”后缀），获取 20+ 篇高质量文档；
- LLM 生成**：调用 DeepSeek API，基于真实文档生成一条完整测试数据——含有难度的问题、正确答案、5 篇支撑文档、3 篇反事实文档和 3 个错误答案；
- RGB 格式组装**：将生成结果对齐到 positive / negative / positive_wrong / fakeanswer 标准字段，与 RGB 数据集格式完全一致；
- 质量检查**：自动验证字段完整性与格式合规性。

引擎后端通过 FastAPI SSE 接口实时推送生成进度，前端提供可视化流水线界面，支持一键生成与实时预览。生成的数据直接用于实验流水线。图 2 展示了一条以”黑洞”为关键词生成的测试数据案例，包含问题、正确答案、4 篇支撑文档、5 篇语义噪音文档和 2 篇反事实文档（红色标注处为被篡改的关键信息）。

Question

基于黑洞的形成、观测和理论发展，请分析为什么黑洞长期以来被认为是数学上的好奇，直到20世纪60年代后才被接受为天体物理实体？

Answer

黑洞长期被视为数学好奇，因为史瓦西解（1916）缺乏物理解释，芬克尔斯坦1958年才解释为不可逃逸区域。20世纪60年代后，中子星发现（1967）激发兴趣，理论工作显示黑洞是广义相对论的一般预测，随后通过X射线、恒星轨道和引力波观测证实。

支撑文档 Positive 4 篇

- P0** 黑洞是一种天体，因极高密度产生极大引力，所有粒子与光无法逃逸。广义相对论预测足够紧密的质量可扭曲时空形成黑洞...
- P1** 1916年史瓦西发现第一个广义相对论精确解，1958年芬克尔斯坦首次将其解释为无法逃逸的空间区域...
- P2** 20世纪60年代理论工作显示黑洞是广义相对论一般预测。1967年贝尔发现中子星，激发了人们对引力坍缩致密天体的兴趣...
- P3** 观测证据在20世纪后期逐步积累：X射线喷流、恒星轨道确定质量、2016年LIGO直接探测到引力波...

噪音文档 Negative 5 篇

- N0** 黑洞信息悖论是量子力学与广义相对论结合时的难题。1970年代霍金发现黑洞会发出霍金辐射...
- N1** 恒星黑洞是大质量恒星引力坍缩后形成的黑洞，质量五至数十倍太阳。目前已知最大质量恒星黑洞 15.65 ± 1.45 倍...
- N2** 超大质量黑洞质量是太阳的 10^6 至 10^9 倍。一般相信所有大型星系中心都存在超大质量黑洞...
- N3** 霍金（1942—2018），英国理论物理学家，贡献包括彭罗斯-霍金奇点定理及霍金辐射理论预测...
- N4** 黑洞热力学发展于1970年代，将热力学定律应用于黑洞研究，暗示广义相对论与量子理论的深刻联系...

反事实文档 2 篇

- CF0** ...史瓦西1916年发现解，1958年芬克尔斯坦解释。直到**20世纪80年代**，贝尔伯奈尔发现中子星才激发兴趣...
- CF1** ...20世纪60年代理论工作显示黑洞是一般预测。1967年，**约翰·米歇尔**发现中子星，激发了引力坍缩致密天体兴趣...

篡改策略：CF0 将年份 60年代→80年代；CF1 将人物 贝尔伯奈尔→约翰·米歇尔

图 2: 数据引擎生成案例：关键词”黑洞”→ 自动构造 RAG 鲁棒性测试数据

3 系统设计

3.1 总体架构

系统由数据层、噪音构造层、推理与矫正层、评估层、可视化与前端层组成。其核心思想是：先从 RGB 数据集中读取问题、答案和文档池，再按实验条件注入噪音，最后调用不同 RAG/矫正方法生成答案并计算指标。




图 3: 系统总体框架图

3.2 调用流水线

单次实验的主流程如下：

1. **加载数据**：读取指定语言和子集的 RGB 样本；
2. **注入噪音**：按噪音比例、类型、位置批量构造含噪上下文；
3. **选择方法**：根据实验条件选择 naive、prompt、iterative、confidence、selfrag、voting、adaptive、ablated 消融变体或 iterative_sc；
4. **调用模型**：访问 DeepSeek API，使用 sha1 缓存减少重复调用；
5. **计算指标**：输出基础问答指标与鲁棒性指标；
6. **落盘与可视化**：保存 JSON，生成图表，并同步报告与前端展示。

3.3 模块组织

系统按功能分层组织为以下模块：

表 5: 系统模块划分

模块	功能
数据层	RGB 与 NoiserBench 数据加载、标准化为统一格式
噪音构造层	比例、类型、位置三维度噪音注入
推理与矫正层	12 个矫正方法（含 4 个深化方向）
评估层	EM/Contains/Token-F1/ROUGE-L 基础指标 + NS/NRS/ISR/NAR/CRR 鲁棒性指标
数据构建引擎	维基爬取 → LLM 生成 → RGB 格式组装 → 质量检查
实验脚本	4 组核心实验 + 通用运行器
Web 系统	FastAPI 后端 + Vue 3 前端 + Gradio Demo

4 方法设计

4.1 噪音注入机制

设最大上下文文档数为 K ，目标噪音比例为 r 。系统从 **positive** 中采样 $K(1-r)$ 个有效文档，从噪音池中采样 Kr 个噪音文档。噪音类型包括：

- **semantic**: 从 **negative** 中采样普通语义噪音；
- **counterfactual**: 从 **positive_wrong** 中采样反事实噪音；
- **mixed**: 同时混合普通噪音和反事实噪音。

噪音位置包括 **front**、**back**、**interleave**、**surround**，用于观察上下文位置偏见对回答的影响。

4.2 矫正方法

表 6: 已实现矫正方法 (共 12 个)

方法	核心思想	API	适用场景
naive	直接拼接文档生成答案	1	基线
prompt (A)	要求识别噪音、标注来源、指出矛盾	1	反事实噪音最优
iterative (B)	逐文档打 high/mid/low $\rightarrow$ 过滤 $\rightarrow$ 生成	$n + 1$	语义噪音候选
confidence (C)	拆解需求 $\rightarrow$ 逐篇标注证据 $\rightarrow$ 综合 $\rightarrow$ 输出	1	语义噪音最优
selfrag	简化 Self-RAG: 相关判定 $\rightarrow$ 生成 $\rightarrow$ 支撑校验	$n + 2$	现有方法对比
voting (D)	3 Persona 独立推理 $\rightarrow$ 多数投票/聚合	3-4	反事实噪音候选
adaptive	自动检测噪音类型 $\rightarrow$ 路由最优方法	2-4	稳健默认选择
iterative_sc	生成 $\rightarrow$ 自检矛盾 $\rightarrow$ 重读 $\rightarrow$ 修订 (3 轮)	3-7	迭代优化
ablated_*	消融变体 (拆解/证据/标签各去掉一环节)	1	因果分析

4.3 深化方法详解

方向 1: 自适应矫正器 (Adaptive Corrector)。首先用 1 次 API 调用快速扫描文档, 检测是否存在明显矛盾/反事实陈述。若检测到 CF (反事实), 路由到 PromptCorrector; 若检测为 CLEAN, 路由到 ConfidenceCorrector (CoT 证据链); 若不确定, 路由到 VotingCorrector 稳健兜底。总 API 调用 2-4 次。

方向 2: 语义级 ISR/NAR。将字符级 token 重叠升级为 LLM 驱动的句子级信息归属判定。每个答案拆分为最小信息单元, LLM 逐条标注来源文档、可信度, 并检测幻觉内容。

方向 3: Confidence 消融实验。创建 4 个变体: C_full (完整四步)、C_no_decompose (去掉拆解信息需求)、C_no_evidence (去掉逐篇证据匹配——最关键的消融)、C_no_tag (去掉 <answer> 标签约束)。用于验证哪一步是 CoT 证据链的核心。

方向 4: 迭代自纠正循环。Round 0 初答 → Round 1 自检矛盾 + 标记可疑文档 + 修订 → Round 2 再自检 + 再修订 → 最多 3 轮或收敛则停。每轮记录 ISR/NAR 变化。

5 评估指标设计

5.1 基础问答指标

- **EM**: 规范化后完全匹配;
- **Contains**: 参考答案是否被预测答案包含;
- **Token-F1**: token 级精确率与召回率调和平均;
- **ROUGE-L**: 基于最长公共子序列的 F1;

5.2 自主鲁棒性指标

表 7: 鲁棒性指标体系

指标	定义与含义
NS	Noise Sensitivity, $NS = (S_{clean} - S_{noisy})/S_{clean}$, 衡量噪音导致的相对性能下降
NRS	Noise Resistance Slope, 性能随噪音比例变化的线性斜率, 越接近 0 越稳健
ISR	Info-Source Rate, 答案有效片段可溯源至 positive 文档的比例
NAR	Noise Adoption Rate, 答案有效片段来自 negative 或 positive_wrong 文档的比例
CRR	Correction Recovery Rate, 矫正方法相对 noisy baseline 恢复了多少性能损失

6 实验结果

所有实验均在 n=50 级别上运行, 使用 DeepSeek-chat API, sha1 缓存确保零重复成本。完整覆盖 zh/en 双语言 × 5 组实验 × 17 个独立配置。

6.1 实验一：噪音影响分析

6.1.1 主矩阵 (zh/main)




图 4: 噪音比例与类型对 Token-F1 的影响 (zh/main)

表 8: 噪音影响详细数据 (semantic, zh/main, n=50)

噪音比例	0.00	0.25	0.50	0.75	1.00
Token-F1	0.768	0.773	0.773	0.725	0.216
Contains	0.860	0.860	0.860	0.800	0.180
ISR	0.600	0.560	0.640	0.540	0.000
NAR	0.000	0.000	0.000	0.000	0.400

发现 1: U 型抗噪 + 断崖效应。在 0–75% 噪音下 F1 从 0.768 仅小幅波动至 0.725 (-5.6%)。但当 positive 文档完全消失 ($r=1.0$) 时 F1 断崖式下跌至 0.216 (-71.9%)，同时 NAR 跃升至 0.400。LLM 的鲁棒性主要来自 positive 文档的兜底作用，而非模型自身对噪音的识别能力。

6.1.2 反事实数据集 (zh/fact)

使用含 `positive_wrong` 文档的 `fact` 子集，三类噪音 (semantic / counterfactual / mixed) 得以真正分离。`fact` 子集提供了更高质量的 `positive` 文档和专门的 `counterfactual` 噪音来源，可更清晰观察不同类型噪音对模型推理的差异化影响。




图 5: zh/fact 数据集上三种噪音类型随噪音比例的性能变化

表 9: zh/fact 数据集上的噪音影响详细数据 (n=50)

噪音比例	semantic		counterfactual		mixed
	F1	Contains	F1	Contains	
0.00 (clean)	0.895	0.960	0.895	0.960	0.895
0.25	0.909	0.960	0.903	0.940	0.915
0.50	0.901	0.940	0.870	0.940	0.883
0.75	0.860	0.940	0.812	0.840	0.725
1.00	0.518	0.500	0.284	0.060	0.500

从图中可以清晰观察到三类噪音的差异化表现：

- **Semantic 噪音 (蓝线)**：在 0–75% 比例下性能稳定 (F1 始终 ≥ 0.86)，仅 $r=1.0$ 时跌至 0.518。语义相关但不直接支持答案的文档对模型推理干扰有限，模型展现出 U

型抗噪特征；

- **Counterfactual 噪音 (橙线)**：呈单调下降趋势。 $r=0.25$ 时 $F1=0.903$ ， $r=0.50$ 降至 0.870 ， $r=0.75$ 降至 0.812 。 $r=1.0$ 时崩盘至 0.284 ，Contains 仅 0.060 ——模型几乎完全被反事实文档误导。下降曲线为近线性而非 U 型，表明反事实文档的破坏力随比例线性累积；
- **Mixed 噪音 (绿线)**：介于两者之间， $r=1.0$ 时 $F1=0.500$ （高于 counterfactual 的 0.284 但略低于 semantic 的 0.518 ）。

发现 2：反事实噪音破坏力显著高于语义噪音。 $r=1.0$ 时 counterfactual $F1=0.284$ 仅为 semantic $F1=0.518$ 的约 55%，Contains 从 0.960 暴跌至 0.060 ——即便答案仍然部分包含在上下文中，模型也不再输出正确答案。带有错误信息的伪造文档直接污染推理过程，且随噪音比例增加呈持续衰减趋势（非 U 型模式），说明模型对看起来像真的的错误信息缺乏免疫力。

6.1.3 噪音位置效应




图 6: 位置效应对比: $r=0.5$ semantic vs $r=0.75$ counterfactual

表 10: 位置效应 ($r=0.75$ counterfactual, zh/fact, $n=50$)

位置	interleave	surround	front	back
Token-F1	0.750	0.706	0.681	0.629
Contains	0.800	0.740	0.740	0.700

发现 3: recency bias 在反事实噪音下有害。 $r=0.5$ 语义噪音时四种位置几乎无差异。但在 $r=0.75$ 反事实噪音下 back 性能最差 (0.629)，与最好的 interleave (0.750) 相差 0.121。这表明反事实文档放在末尾时，recency bias 使错误信息覆盖正确文档的信息。

6.1.4 跨语言对比




图 7: 中英文噪音影响对比 (semantic, $n=50$)

中文 baseline (0.768) 比英文 baseline (0.620) 高 0.148，与 DeepSeek-chat 的中文预训练优势一致。但 U 型抗噪模式和断崖效应在两种语言下完全一致，鲁棒性行为具有跨语言一致性。

6.2 实验二：矫正方法对比

6.2.1 主实验 (zh/main, semantic)




图 8: 五种矫正方法在不同噪音比例下的 F1 表现 (zh/main)

中高强度噪音 ($r=0.75$) 下, confidence 方法 $F1=0.791$ 相比 naive (0.725) 提升 0.067。prompt 方法最差 (0.704)。selfrag 在所有噪音比例下均等于 naive, DeepSeek-chat 的 RELEVANT 判定过宽。

6.2.2 反事实数据集验证 (zh/fact, counterfactual)

表 11: 五种矫正方法在 counterfactual 噪音下的表现 (zh/fact, $n=50$)

方法	$r=0.00$	$r=0.25$	$r=0.50$	$r=0.75$
naive	0.895	0.903	0.870	0.812
prompt	0.890	0.901	0.876	0.813
iterative	0.895	0.893	0.871	0.750
confidence	0.901	0.930	0.877	0.712
selfrag	0.895	0.903	0.870	0.812

发现 4: 互锁效应跨数据集验证。 confidence 在低噪音下最佳 ($r=0.25$ 时 $F1=0.930$), 但在 $r=0.75$ 时崩溃至 0.712 (低于 naive 的 0.812)。prompt 在 $r=0.75$ 下最稳定 (0.813), 证实简单指令在反事实场景的有效性。

6.3 实验三：案例深度分析

实验三通过 clean / noisy (naive) / corrected (confidence) 三组对比，将案例按以下四种类型分类：

- **Type1-生效**：clean 对 → noisy 错 → corrected 恢复
- **Type1-未生效**：clean 对 → noisy 错 → corrected 仍错
- **Type3-信息淹没**：clean 错 → noisy 错
- **Type4-免疫**：clean 对 → noisy 对

6.3.1 zh/main 与 zh/fact 对比




图 9: zh/main 案例类型分布与性能恢复

zh/main 上 $r=0.5$ 和 $r=0.75$ 下 Type4（免疫）占多数，confidence 修正效果随噪音增强逐渐显著。 $r=1.0$ 时修正基本无效。




图 10: zh/fact 案例类型分布与性能恢复

表 12: zh/fact 案例类型分布 (三组 ratio, 每组 pick=20)

ratio	Type1-生效	Type1-未生效	Type3-淹没	Type4-免疫
0.50	1 (5%)	0 (0%)	2 (10%)	17 (85%)
0.75	0 (0%)	1 (5%)	2 (10%)	17 (85%)
1.00	3 (15%)	17 (85%)	0 (0%)	0 (0%)

发现 5: fact 数据集高度抗噪。 fact 的 positive 文档质量更高: $r=0.5$ 和 $r=0.75$ 下 85% 案例为 Type4 (免疫)。但 $r=1.0$ (positive 文档全消失) 时断崖效应再次出现: 85% 案例矫正未生效。

6.3.2 英文案例研究 (en/main)




图 11: en/main 案例类型分布与性能恢复

英文 baseline ($F1=0.601$) 低于中文, 但 confidence 矫正同样释放正向效果, 矫正方法的跨语言有效性得到验证。

6.4 实验四: 互锁效应——方法 $\times$ 噪音类型交互

6.4.1 核心实验: $r=0.75$ 互锁矩阵 (zh)

这是本工作最核心的实验发现。




图 12: 互锁效应: 六种方法在 semantic 与 counterfactual 噪音下的表现 ($r=0.75$)

表 13: 互锁效应详细数据 ($r=0.75$, $n=50$)

方法	Semantic		Counterfactual	
	F1	Δ naive	F1	Δ naive
confidence	0.791	+0.067	0.708	-0.042
prompt	0.704	-0.020	0.781	+0.031
voting	0.730	+0.005	0.758	+0.008
naive	0.725	—	0.750	—
selfrag	0.725	0.000	0.750	0.000
iterative	0.724	-0.001	0.688	-0.062

6.4.2 $r=0.5$ 对照与排名稳定性

表 14: 六种方法在 $r=0.5$ 下的表现（三种噪声类型, $n=50$ ）

方法	Semantic	Mixed	Counterfactual (fact)
confidence	0.803	0.803	0.886
voting	0.768	0.767	0.894
iterative	0.781	0.781	0.830
naive	0.773	0.773	0.815
selfrag	0.773	0.773	0.815
prompt	0.741	0.741	0.851




图 13: 方法排名稳定性: $r=0.5$ vs $r=0.75$

发现 6: 互锁效应——最优方法取决于噪音类型。

- **Semantic 噪音:** CoT 证据链 (confidence) 最优, $F1=0.791$ ($\Delta_{naive}=+0.067$)。逐篇证据匹配自然过滤不相关文档;
- **Counterfactual 噪音:** confidence 跌至 0.708 (比 naive 还差), CoT 被”假证据”绑架——推理越严密被骗后越自信; 而 prompt 从末位逆袭为首位 ($F1=0.781$);
- **Voting 最稳健:** 两种噪音下均排第 2, 是最安全的默认选择;
- **SelfRAG 始终 = naive:** DeepSeek-chat 无法区分”相关但误导”的文档。

在 $r=0.5$ 下方法差距较小, 噪音增强到 $r=0.75$ 后互锁效应完全显现。

6.4.3 英文互锁验证 (en/main)

表 15: 英文 semantic 噪音下的方法对比 (en/main, $r=0.75$, $n=50$)

方法	Token-F1	Contains	ISR	NAR
confidence	0.678	0.60	0.671	0.082
iterative	0.628	0.60	0.778	0.039
prompt	0.626	0.58	0.634	0.091
voting	0.621	0.60	0.611	0.055
naive	0.601	0.56	0.614	0.084
selfrag	0.601	0.56	0.614	0.084

英文语义噪音下 confidence 同样最优 ($F1=0.678$)，排名与中文一致，验证互锁效应跨语言稳定。英文 baseline (0.601) 显著低于中文 (0.725)。

6.5 实验五：深化实验

6.5.1 Confidence 消融实验

表 16: Confidence 方法消融对比 (semantic $r=0.75$, $n=20$)

变体	zh F1	en F1
naive baseline	0.685	0.558
confidence (正常调用)	0.683	0.585
C_full (消融对照版)	0.683	0.534
C_no_decompose (去掉拆解)	0.704	0.561
C_no_evidence (去掉证据)	0.697	0.554
C_no_tag (去掉标签)	0.679	0.550

发现 7: 英文消融全负——CoT 证据链的跨语言不对称性。

- **中文**：去掉拆解需求反而提升 ($0.704 > 0.683$)，说明中文下 CoT 过度拆解可能引入噪声。去掉标签约束导致最严重下降 (0.679)， $\langle answer \rangle$ 标签对中文输出约束至关重要；

- **英文**: 所有消融变体均低于或仅持平 naive baseline (0.558)。confidence 正常调用可获 +4.8% 增益 (0.585), 但消融版的 C_full (0.534) 反而比 naive 还差 4.3%。这表明: 英文下 CoT 证据链的每一步都对最终质量有贡献, 任何一个环节的 prompt 质量下降都会导致输出崩溃;
- **中英差异**: 中文即便消融部分步骤仍可保持 $F1 > 0.67$ (远高于 naive 0.685); 英文消融后 F1 全部跌落至 0.53–0.56 区间, 接近甚至低于 naive, 反映出英文场景下 CoT 推理对 prompt 质量高度敏感。

6.5.2 语义级 ISR/NAR

语义级溯源将字符级 token 重叠升级为 LLM 驱动的信息归属判定。5 个英文样本测试中语义 ISR 均为 1.0, 无幻觉内容检出。语义 ISR 通常低于字符级 ISR, 表明字符级方法可能高估信息溯源率。

6.5.3 自适应矫正器

设计动机: 实验四揭示了互锁效应——confidence 在语义噪音下最优 ($F1=0.791$) 但在反事实噪音下崩溃 (0.708, 比 naive 还差), 而 prompt 在反事实噪音下逆袭 (0.781)。一个理想系统应能自动识别噪音类型并路由到最优方法。

三阶段架构:

1. **噪音检测器** (1 次 API, max_tokens=16, temperature=0): 将文档截断至每篇 1200 字符 → LLM 扫描是否存在反事实/矛盾陈述 → 输出 CF / CLEAN。使用独立系统提示和独立 max_tokens (16 vs RAG 的 512), 通过缓存键隔离避免与主 RAG 调用碰撞;
2. **多级解析**: 精确匹配 CF/CLEAN → 中文语义匹配 (反事实/有矛盾/虚构 → CF; 无矛盾/一致 → CLEAN) → 兜底 UNCERTAIN;
3. **路由**: CF → PromptCorrector (标注来源 + 指出矛盾, 反事实下 $F1=0.781$); CLEAN → ConfidenceCorrector (CoT 证据链, 语义下 $F1=0.791$); UNCERTAIN → VotingCorrector (多 Persona 稳健兜底)。

验证结果 (zh/fact, $r=0.75$, $n=30$):

表 17: 自适应矫正器验证 (zh/fact, $r=0.75$, $n=30$)

方法	Semantic F1	Counterfactual F1	路由分布
naive	0.822	0.738	—
confidence (semantic 最优)	0.863	0.713	—
prompt (counterfactual 最优)	—	0.763	—
adaptive	0.831	0.763	CF=11/19 (sem) / CF=30/0 (cf)

发现 8：自适应有效避免最差情况。

- **Semantic 噪音**：adaptive F1=0.831, +1.1% vs naive (0.822), 略低于 confidence (0.863)。19/30 样本正确路由到 confidence, 11/30 检测器过于敏感误判为 CF；
- **Counterfactual 噪音**：adaptive F1=0.763, 等于最优方法 prompt (0.763), +3.4% vs naive (0.738)。30/30 全部正确检测为 CF 并路由到 prompt, 完美避开了 confidence 的崩溃 (0.713)；
- **关键价值**：adaptive 不会选择”错误”的方法。即使用 confidence 在 CF 下崩溃 6.9%, adaptive 始终 $\geq$ naive, 在最危险的反事实场景下与已知最优方法持平。

6.5.4 迭代自纠正

英文 $n=10$ 测试中 iterative_sc 的 F1=0.375 低于 naive baseline 的 0.492, 所有样本均未达成收敛。当前实现仍在优化中, 主要挑战在于大模型自检的矛盾判断准确率不足。

7 后期实验：跨数据集验证

中期实验 (§6) 在 RGB 上揭示了 U 型抗噪、互锁效应与自适应路由等核心规律。后期工作在**相同评估框架**下扩展至多领域数据集, 回答: 这些规律是否可迁移? 不同语料形态 (多跳、医学、OCR 记忆) 下最优矫正策略是否一致?

7.1 实验设置

表 18: 后期实验与中期实验的设置差异

维度	中期 (§6 主实验)	后期 (本节)
主数据集	RGB zh/en	2Wiki、Cmedqa、MobileMem 等
生成模型	DeepSeek-chat (API)	本地 qwen3-4b (LM Studio) + DeepSeek Judge
主指标	Token-F1 / Contains	Judge Score (MobileMem) 或 Token-F1 (2Wiki/Cmedqa)
方法子集	5-6 种全量对比	naive / prompt / confidence / voting (性价比子集)
噪音配置	全比例梯度 + 三类型	semantic, $r \in \{0, 0.5, 0.75\}$

说明: 中期 RGB 结果仍作为**主文核心结论**; 后期结果用于跨数据集对照, 表头均标注样本规模 n 与指标类型, 避免与中期 DeepSeek 端到端数值直接混比。

7.2 2WikiMultihopQA (英文多跳, $n = 500$)

7.2.1 实验一: 噪音影响




图 14: 2Wiki 上 naive 方法的 semantic 噪音梯度 ($n = 500$)

2Wiki 上 naive 基线呈现与 RGB 一致的 **U 型抗噪 + 断崖效应**: $r = 0$ 时 $F1=0.619$, 0–75% 区间缓慢降至 0.422 (–31.8%), $r = 1.0$ 时跌至 0.067 (–89.2%)。说明多跳 hard negative 场景下, positive 文档仍是答案质量的决定性因素。

7.2.2 实验二：矫正方法对比




图 15: 2Wiki 上多方法矫正对比 (semantic, $n = 500$)




图 16: 2Wiki 各方法随噪音比例变化 (Token-F1)

在 $r = 0.75$ 高强度 semantic 噪音下，各方法 Token-F1 为：confidence=0.577 > voting=0.510 > naive=0.422 > prompt=0.406。这与 RGB 上语义噪音下 CoT 证据链最优的互锁模式一致；confidence 的 CRR=1.33，相对 naive 有明显恢复。




图 17: 2Wiki Exp4: $r = 0.75$ semantic 下六方法对比 ($n = 500$)

7.2.3 反事实子集 (fact, $n = 500$)

2Wiki fact 子集由脚本从 hard negative 自动构造 positive_wrong，质量弱于 RGB 原版实体替换。naive 在 counterfactual 噪音下 F1 整体偏低 ($r = 0$ 仅 0.093)，但仍观察到 $r = 1.0$ 断崖 (0.012)，与主集规律一致。

7.3 MobileMem (中文 OCR 记忆 RAG, calc 子集, $n = 50$)

MobileMem 证据来自购物截图 OCR 文本，问题需跨多条记忆事件聚合计算，更贴近移动端记忆助手场景。本集采用 DeepSeek Judge 作为主指标（短答案/计算类更适合 LLM 判别）。




图 18: MobileMem calc: naive Judge Score 随 semantic 噪音变化 ($n = 50$)




图 19: MobileMem calc: 四方法矫正对比 (Judge Score, $n = 50$)

表 19: MobileMem calc 关键结果 (Judge Score / Judge Correct@ $r = 0.75$)

方法	clean ($r = 0$)	$r = 0.5$	$r = 0.75$	NS
naive	0.808 / 72%	0.764 / 66%	0.440 / 18%	0.255
confidence	0.804 / 68%	0.772 / 64%	0.536 / 30%	0.187
prompt	0.720 / 58%	0.724 / 60%	0.468 / 22%	0.172
voting	0.812 / 72%	0.704 / 58%	0.468 / 22%	0.278

发现 9: OCR 记忆场景下 confidence 在高噪音时优于 naive。 $r = 0.75$ 时 confidence Judge=0.536, 比 naive (0.440) 高 21.8%, Judge 正确率 30% vs 18%。voting 在 clean 时最优 (0.812), 但高噪音下与 prompt 同为 0.468, API 成本不值得。




图 20: MobileMem 四方法鲁棒性雷达图 (NS/NRS/ISR/NAR)

7.4 CmedqaRetrieval (中文医学, $n = 3999$)




图 21: Cmedqa 全量矫正对比 (semantic, $n = 3999$)

医学长答案场景 baseline F1 整体较低 (naive clean=0.210)。有趣的是, confidence 在噪音下**未下降**: $r = 0.75$ 时 $F1=0.268$, 略高于 clean (0.268 vs 0.210 为 naive; confidence clean=0.268), $CRR=5.17$, 说明 CoT 证据链在专业术语密集文本中有一定纠错能力。闭卷基线 ($n = 50$) $F1=0.155$, 低于 RAG naive (0.195), 验证检索对医学 QA 的必要性。

7.5 跨数据集 Judge 梯度对比




图 22: RGB / 2Wiki / Cmedqa 上 naive 的 Judge Score 噪音曲线 ($n = 50-500$)




图 23: 2Wiki / Cmedqa 上 naive Token-F1 噪音曲线

跨数据集对比显示数据集难度与抗噪形态差异显著:

- **RGB**: clean Judge=0.912, $r = 0.75$ 仍保持 0.784 (NS=0.112), 抗噪最强;
- **2Wiki**: Judge 在 0.58 附近近乎平坦 (NS $\approx$ 0), F1 曲线则呈 RGB 式断崖;
- **Cmedqa**: prompt clean=0.632 最高, 但 $r = 0.5$ 后跌至 0.468 (NS=0.260), 说明简单指令在医学场景 clean 表现好、噪音下脆弱。

7.6 后期实验小结

表 20: 后期已完成实验清单

数据集	实验	n	状态	主要结论
2Wiki	exp1 + exp2 + exp4	500	已完成	U 型断崖; semantic 下 confidence 最优
MobileMem calc	smoke 批量	50	已完成	$r = 0.75$ confidence > naive (Judge)
Cmedqa	exp2 + 闭卷	3999/50	已完成	医学长答 案; confidence CRR 高
MIRIAD	exp1 + exp2	100	已完成	长生成 baseline 低, 规律待大 n 验证
RGB/Cmedqa/2Wiki	noise_gradient	50–500	已完成	跨数据集 Judge/F1 对比图
BRIGHT/TEMPO/MultiHop	sanity check	100	已验证	数据已接 入, 正式 $n = 50$ 待补
NoiserBench hotpotqa	exp2 试跑	2	已验证	七类噪音机 制已通, 大 规模待跑

发现 10：互锁效应在多跳英文数据上可复现，在 OCR 记忆与医学数据上表现为「confidence 高噪音稳健」而非 prompt 逆袭。这与 RGB fact 上 counterfactual 专用结论并不矛盾——后期扩展集以 semantic hard neg 为主，尚未系统跑 counterfactual 互锁矩阵。

8 系统实现与前端演示

8.1 后端接口

后端使用 FastAPI 实现，提供数据集配置、样本浏览、噪音注入、推理运行等 RESTful 接口，支持前端的全流程交互。

8.2 前端界面

前端使用 Vue 3 + Vite，采用四阶段界面（Stage A：选择数据集和样本 → Stage B：设置噪音参数 → Stage C：查看 Prompt → Stage D：答案与指标展示），可在教师面前现场演示完整的“选择问题 → 注入噪音 → 矫正推理 → 对比答案”流程。同时提供 Gradio Demo 作为备用演示入口。




图 24: 实验平台前端界面

数据构建引擎

爬取真实文档 + LLM 生成 → RAG 鲁棒性测试数据

量子力学

一键生成

1 搜索维基

关键词 → Wikipedia API

2 获取文档

提取正文内容

3 LLM 生成

Q/A + 反事实

4 组装输出

RGB 兼容格式

✓ 搜索维基百科

— 找到 19 篇文章

埃尔温·薛定谔 | 薛定谔 | 量子力学的数学表述 | 關係性量子力学 | 量子拓扑 | 范德瓦耳 | 量子力学的宇宙学诠释 | 量子力学的数学基础 | 构造原理 | +11

✓ 获取文档内容

— 获取 11 篇文档

埃尔温·薛定谔-埃尔温·鲁道夫·约瑟夫·亚历山大·薛定谔（德语：Erwin Rudolf Josef Alexander Schrödinger；1887年8月12日—1961年1月4日），奥地利理论物理学家，量子力学奠基人之一。1926年提出薛定谔方程，提供计算波函数及其演化的方法，为量子力学奠定坚实的基础。提出薛定谔猫思想实验，试图证明量子力学在宏观条件下的不完备性，探讨量子力学中的测量和叠加态的概念。19

量子力学的数学表述：量子力学的数学表述（Mathematical formulation of quantum mechanics）是对量子力学进行严谨描述的数学表述体系。与20世纪初发展起来的旧量子论的数学形式不同，它使用了一些抽象的代数结构，如无穷维希尔伯特空间和这些空间上的算子。这些结构中有许多源于泛函分析。这一纯粹数学研究领域的发展过程既平行于又受影响于量子力学的需要。简而言之，物理可观察量的值，如能量和动量

關係性量子力学：關係性量子力学（英语：Relational quantum mechanics, RQM）是一種量子力学诠释，此理论認為量子系統的量子都是隨觀察者而變的；也就是說，量子都是觀察者與系統之間的關係。此一诠释最早是由卡洛·羅威利在一份1994年的预印本中提出，隨後由許多理論物理學家擴充。這個想法主要受到狹義相對論的激勵，其闡述了觀察到的細節隨不同參考系的觀察者而變，並採用到約翰·惠勒對量子資訊的一些看法

✓ LLM 生成测试数据

Q: 薛定谔在1935年创造术语“量子纠缠”是否直接源于他对薛定谔猫思想实验的推导？

A: 不是，薛定谔猫思想实验于1935年提出，旨在探讨量子叠加态和测量问题，而“量子纠缠”一词是同年他在另一篇论文中创造的，用于描述量子系统间的非局域关联，两者并非直接推导关系。

✓ 组装 RGB 格式

— 4P · 10N · 4CF

问题

薛定谔在1935年创造的术语“量子纠缠”是否直接源于他对薛定谔猫思想实验的推导？

正确答案

不是，薛定谔猫思想实验于1935年提出，旨在探讨量子叠加态和测量问题，而“量子纠缠”一词是同年他在另一篇论文中创造的，用于描述量子系统间的非局域关联，两者并非直接推导关系。

Positive (4)

P0 埃尔温·鲁道夫·约瑟夫·亚历山大·薛定谔（德语：Erwin Rudolf Josef Alexander Schrödinger；1887年8月12日—1961年1月4日），奥地利理论物理学家，量子力学奠基人之一。1926年提出薛定谔方程，提供计算波函数及其演化的方法，为量子力学奠定坚实的基础。按…

P1 薛定谔于1935年创造了“量子纠缠”一词，用于描述两个或多个粒子在量子态上相互依赖的现象，即使它们相隔遥远，测量一个粒子会瞬间影响另一个。这一概念后来成为量子信息科学的基础。…

P2 薛定谔猫思想实验是薛定谔在1935年提出的，旨在通过一个宏观的猫被置于生死叠加态的例子，质疑量子力学在宏观尺度下的完备性，强调测量和叠加态的概念。…

P3 薛定谔的学术贡献包括薛定谔方程、量子纠缠和薛定谔猫思想实验。这些成果分别发表于

Negative (10)

N0 量子力学的数学表述（Mathematical formulation of quantum mechanics）是对量子力学进行严谨描述的数学表述体系。与20世纪初发展起来的旧量子论的数学形式不同，它使用了一些抽象的代数结构，如无穷维希尔伯特…

N1 關係性量子力学（英语：Relational quantum mechanics, RQM）是一種量子力学诠释，此理论認為量子系統的量子都是隨觀察者而變的；也就是說，量子都是觀察者與系統之間的關係。此一诠释最早是由卡洛·羅威利在一份1994年的…

N2 量子拓扑（英语：Quantum topology）是连接量子力学与低维拓扑的数学分支。狄拉克符号给出了量子力学的一种观点，被推广成为可以包含拓扑空间相关振幅和空间之间的相关嵌入的框架，例如三维空间中的结和纽结。狄拉克符号对右矢和左矢的表示…

N3 范德瓦耳力（英语：van der Waals force）又名范德瓦耳斯力，简称范氏力。根据荷兰物理

反事实 (4)

CF0 薛定谔于1935年创造了“量子纠缠”一词，这一术语直接源于他对薛定谔猫思想实验的推导，因为猫实验揭示了粒子间的纠缠关系，从而定义了量子纠缠。…

CF1 薛定谔猫思想实验是薛定谔在1935年提出的，该实验直接导致了量子纠缠概念的诞生，因为猫的生死叠加态本质上是量子纠缠的宏观表现。…

CF2 薛定谔在1935年创造了“量子纠缠”一词，用于解释薛定谔猫思想实验中的现象，即猫与放射性原子之间的纠缠状态，从而统一了这两个概念。…

CF3 薛定谔猫思想实验的核心是量子纠缠，薛定谔通过该实验首次提出了纠缠的概念，因此1935年他创造“量子纠缠”一词是对该实验的总结。…

图 25: 数据构建引擎前端界面

9 当前进度

表 21: 项目完整完成情况

模块	内容	状态
数据处理	RGB 8 个 JSONL 文件加载与标准化	已完成
噪音注入	比例、类型、位置三维控制	已完成
模型调用	DeepSeek API、sha1 缓存、重试、token 统计	已完成
矫正方法	12 个矫正器（含 4 个深化方向）	已完成
评估指标	EM、Contains、Token-F1、ROUGE-L、NS/NRS/ISR/NAR/CRR	已完成
语义级溯源	LLM 驱动的句子级信息归属	已完成
实验脚本	exp1-exp5 与通用 runner	已完成
可视化	折线、分组柱、雷达、互锁热力图、排名图、跨语言对比等	已完成
测试套件	test_evaluator, test_metrics, test_noise_injector	已完成
Web 系统	FastAPI 后端 + Vue 3 前端 + Gradio Demo	已完成
后期 2Wiki 实验	exp1/exp2/exp4, $n = 500$	已完成
后期 MobileMem 实验	smoke 四方法, $n = 50$	已完成
后期 Cmedqa 实验	exp2 全量 + 闭卷基线	已完成
后期跨数据集可视化	render_late_stage_figures.py	已完成
BRIGHT/TEMPO 正式实验	$n = 50$ 批量	计划中
文档逻辑支撑度分析	构造 LSL 三维度 (full_chain/partial_premise/topic_only), 分析对模型推理的影响	计划中
逻辑依赖评估指标	提出 PCR(前提覆盖度)/LCI(逻辑一致性)/RCG(推理链缺口) 并验证	计划中
逻辑链感知提示词矫正	设计显式前提匹配 + 推理链完整性检查的结构化 prompt, 对比现有方法	计划中
前提补全式迭代矫正	多步流程: 初答 → 自检推理链缺口 → 补全前提 → 重新生成, 记录缺口类型与补全率	计划中

10 与现有方法的比较

表 22: 本工作方法与现有方法的比较

维度	Self-RAG (2024)	CRAG (2024)	本工作
核心机制	反思 token 门控	分解-重组流水线	证据链 + 多 Persona+ 自适应路由
噪音感知	隐式（相关判定）	隐式	显式（噪音类型检测 + 路由）
评估粒度	端到端指标	端到端指标	端到端 +ISR/NAR+ 语义级溯源
噪音类型适配	单一策略	单一策略	互锁效应驱动的类型自适应
API 成本	高 (n+2)	中	低-中 (1-4), 自适应仅 +1
中文评测	无系统评测	无系统评测	RGB zh 完整评测

创新点总结：

1. 发现了“互锁效应”——最优矫正方法取决于噪音类型，CoT 证据链在语义噪音下最优但在反事实噪音下反而有害；
2. 提出并验证了自适应矫正器，利用噪音类型检测实现方法路由；
3. 提出语义级 ISR/NAR，将 token 重叠升级为 LLM 驱动的信息归属判定；
4. 发现了在高强度反事实噪音下的位置效应，back 位置最差，interleave 最优；
5. 提供了中英文跨语言 RAG 鲁棒性基准；
6. 构建了自动化数据引擎，从维基百科爬取真实文档并用 LLM 生成高质量 RAG 测试数据，支持按需扩展 benchmark。

11 运行方式

项目基于 Python 3.10 和 Node.js 环境，运行步骤如下：

1. 安装 Python 依赖并配置 DeepSeek API 密钥；
2. 运行单元测试验证环境配置正确；

3. 通过实验脚本依次执行 exp1（噪音影响）、exp2（矫正方法）、exp3（案例研究）、exp4（互锁效应）实验，支持指定语言、样本数和噪音参数；
4. 运行图表渲染脚本自动生成所有实验图表；
5. **后期图表**: `python scripts/render_late_stage_figures.py` 生成跨数据集对比图至 `report_final/figures/`；
6. 启动 FastAPI 后端和 Vue 前端（或 Gradio Demo）进行系统演示。

12 总结

本项目围绕“大模型 RAG 场景中检索文档噪音对推理的影响”这一核心问题，实现了完整的实验框架、12 种矫正方法和 5 个自主评估指标。在 RGB 上 $n=50$ 级别的实验证实了 U 型抗噪、互锁效应与位置效应；CoT 证据链在语义噪音下表现最优，但在反事实噪音下反而被“假证据”绑架；自适应矫正器可自动路由至最优策略。

后期在 2WikiMultihopQA ($n = 500$)、MobileMem OCR 记忆 ($n = 50$) 和 CmedqaRetrieval ($n = 3999$) 上的实验表明：**多跳英文场景复现了 semantic 下 confidence 最优的互锁模式**；MobileMem 高噪音下 confidence Judge Score 比 naive 高 21.8%；医学长答案场景 confidence 的矫正恢复率 CRR 显著为正。跨数据集 Judge 对比进一步揭示 RGB 抗噪最强、2Wiki Judge 平坦而 F1 断崖、Cmedqa prompt clean 高但噪音脆弱等差异。

四项深化——自适应矫正器、语义级 ISR/NAR、消融实验和迭代自纠正循环——以及 8 类扩展数据集接入，为构建可部署、可扩展的鲁棒 RAG 系统提供了实验依据与工程基线。