



面向大模型 RAG 推理场景 噪音文档的鲁棒性推理方法

NLP 实验四 · 题目 8 · 实验报告

队长姓名：待填写 队长学号：待填写

工作区：D:\code\nlpexp4

2026 年 5 月 25 日

目录

1 研究问题与项目定位

1.1 题目要求

本项目对应 NLP 实验四题目 8：**面向大模型 RAG 推理场景噪音文档的鲁棒性推理方法**。题目要求关注大模型 RAG 场景中，检索结果可能包含与问题语义相关、但缺少逻辑依赖或会误导答案的上下文文档，进而影响模型问答准确率。项目需要完成以下任务：

- 探究上下文文档对模型问答性能的影响；
- 提出可量化的评估指标；
- 针对具体数据集给出实验结果、结论与分析；
- 结合具体案例分析不同文档对答案的影响；
- 设计矫正机制，例如提示词优化、迭代式生成等；
- 与现有方法进行性能比较，说明方法有效性与局限。

1.2 核心问题

本项目将问题形式化为：给定问题 q 、候选文档集合 $D = \{d_1, \dots, d_n\}$ 和参考答案 a ，当 D 中混入不同类型、比例和位置的噪音文档时，大模型生成答案 $\hat{a}$ 的准确率、证据来源和噪音采纳程度如何变化？此外，不同的矫正机制在不同噪音类型下表现如何？是否存在“互锁效应”——即最优方法取决于噪音类型。

1.3 核心发现摘要

经过完整的系统实现和 $n=50$ 级别的实验验证，本项目核心发现包括：

- **U 型抗噪 + 断崖效应**：LLM 在 0-75% 噪音下性能几乎不变，但 positive 文档完全消失 ($r=1.0$) 时性能崩溃；
- **互锁效应**：CoT 证据链在语义噪音下最优 ($F1=0.791$)，但在反事实噪音下跌至 0.708 (比 naive 还差)；而简单 prompt 指令在反事实噪音下逆袭为最优 ($F1=0.781$)；
- **位置效应**：在 $r=0.75$ 反事实噪音下，文档放末尾 (back) 的破坏力最大 ($F1=0.629$)，印证 recency bias 在错误信息场景下的危害；
- **跨语言一致性**：英文 baseline (0.620) 显著低于中文 (0.768)，但 U 型抗噪模式跨语言一致；
- **方法深化**：自适应矫正器、语义级 ISR/NAR、消融实验和迭代自纠正循环四项深化工作已实现并验证。

2 数据准备与标准格式

2.1 原始数据

项目使用 RGB 数据集作为公开问答与候选文档来源。数据位于 `data/rgb/`，包含中英文主数据、反事实数据、信息整合数据和 refine 数据：

表 1: RGB 数据文件与用途

数据文件	语言	样本数	用途
zh.json, en.json	中/英	各 300	主问答数据，含 positive 与 negative 文档池
zh_fact.json, en_fact.json	中/英	各 100	反事实噪音数据，额外含 positive_wrong 和 fakeanswer
zh_int.json, en_int.json	中/英	各 100	信息整合类问题，用于后续跨文档推理扩展
zh_refine.json, en_refine.json	中/英	各 300	refine 变体，用于后续泛化验证

2.2 文档池定义

RGB 数据天然给出了适合本题的三类文档池：

表 2: 三类文档池与噪音含义

字段	实验含义	使用方式
positive	支持正确答案的有效文档	构造 clean RAG 上下文，计算 ISR
negative	语义相关但不能支持答案的普通噪音文档	模拟检索噪音，计算 NAR
positive_wrong	表面相关但指向错误答案的反事实文档	模拟更强误导性噪音，测试矫正机制

2.3 课程要求格式对齐

项目已增加标准格式导出脚本 `scripts/export_standard_io.py`，可从实验结果中导出 `input.json`、`output.json`、`reference.json` 等标准文件。

3 系统设计

3.1 总体架构

系统由数据层、噪音构造层、推理与矫正层、评估层、可视化与前端层组成。其核心思想是：先从 RGB 数据集中读取问题、答案和文档池，再按实验条件注入噪音，最后调用不同 RAG/矫正方法生成答案并计算指标。




图 1: 系统总体框架图

3.2 调用流水线

单次实验的主流程如下：

1. **加载数据**：调用 `load_dataset(language, subset, limit)` 读取 RGB 样本；
2. **注入噪音**：调用 `batch_inject` 按噪音比例、类型、位置构造 `NoisyContext`；
3. **选择方法**：根据实验条件选择 `naive`、`prompt`、`iterative`、`confidence`、`selfrag`、`voting`、`adaptive`、`ablated_*` 或 `iterative_sc`；
4. **调用模型**：通过 `LLMClient` 访问 DeepSeek API，使用 `sha1` 缓存减少重复调用；
5. **计算指标**：通过 `Evaluator` 和 `metrics.py` 输出基础问答指标与鲁棒性指标；
6. **落盘与可视化**：保存 JSON，生成图表，并同步报告与前端展示。

3.3 代码结构

```
D:\code\nlpexp4
|-- data/rgb/                RGB 原始数据
|-- src/
|   |-- data_loader.py      RGB 加载与标准化
|   |-- noise_injector.py   噪音比例/类型/位置控制
|   |-- rag_pipeline.py     Naive RAG baseline
|   |-- llm_client.py       DeepSeek API + 缓存 + 重试
|   |-- evaluator.py        EM/F1/ROUGE/LLM-Judge
|   |-- metrics.py          NS/NRS/ISR/NAR/CRR
|   |-- metrics_semantic.py 语义级文档溯源（方向2）
|   |-- correctors/         12个矫正器（含4个深化方向）
|       |-- prompt_corrector.py 方法A: 提示词优化
|       |-- iterative_corrector.py 方法B: 迭代过滤
|       |-- confidence_corrector.py 方法C: CoT证据链
|       |-- voting_corrector.py 方法D: 多Persona投票
|       |-- selfrag_baseline.py SelfRAG对比
|       |-- adaptive_corrector.py 方向1: 自适应路由
|       |-- ablated_confidence.py 方向3: 消融变体
|       |-- iterative_self_correct.py 方向4: 迭代自纠正
|-- experiments/
|   |-- exp1_noise_impact.py
|   |-- exp2_correction.py
|   |-- exp3_case_study.py
|   |-- exp4_existing_methods.py
|   |-- exp5_deep.py        深度实验集成
|-- backend/                FastAPI 接口
|-- frontend/               Vue 3 实验界面
|-- figures/                实验图表
|-- report_latex/           本 LaTeX 报告
```

4 方法设计

4.1 噪音注入机制

设最大上下文文档数为 K ，目标噪音比例为 r 。系统从 `positive` 中采样 $K(1-r)$ 个有效文档，从噪音池中采样 Kr 个噪音文档。噪音类型包括：

- **semantic**: 从 `negative` 中采样普通语义噪音；
- **counterfactual**: 从 `positive_wrong` 中采样反事实噪音；

- **mixed**: 同时混合普通噪音和反事实噪音。

噪音位置包括 front、back、interleave、surround，用于观察上下文位置偏见对回答的影响。

4.2 矫正方法

表 3: 已实现矫正方法 (共 12 个)

方法	核心思想	API	适用场景
naive	直接拼接文档生成答案	1	基线
prompt (A)	要求识别噪音、标注来源、指出矛盾	1	反事实噪音最优
iterative (B)	逐文档打 high/mid/low $\rightarrow$ 过滤 $\rightarrow$ 生成	$n + 1$	语义噪音候选
confidence (C)	拆解需求 $\rightarrow$ 逐篇标注证据 $\rightarrow$ 综合 $\rightarrow$ 输出	1	语义噪音最优
selfrag	简化 Self-RAG: 相关判定 $\rightarrow$ 生成 $\rightarrow$ 支撑校验	$n + 2$	现有方法对比
voting (D)	3 Persona 独立推理 $\rightarrow$ 多数投票/聚合	3-4	反事实噪音候选
adaptive	自动检测噪音类型 $\rightarrow$ 路由最优方法	2-4	稳健默认选择
iterative_sc	生成 $\rightarrow$ 自检矛盾 $\rightarrow$ 重读 $\rightarrow$ 修订 (3 轮)	3-7	迭代优化
ablated_*	消融变体 (拆解/证据/标签各去掉一环节)	1	因果分析

4.3 深化方法详解

方向 1: 自适应矫正器 (Adaptive Corrector)。首先用 1 次 API 调用快速扫描文档，检测是否存在明显矛盾/反事实陈述。若检测到 CF (反事实)，路由到 PromptCorrector；若检测为 CLEAN，路由到 ConfidenceCorrector (CoT 证据链)；若不确定，路由到 VotingCorrector 稳健兜底。总 API 调用 2-4 次。

方向 2: 语义级 ISR/NAR。将字符级 token 重叠升级为 LLM 驱动的句子级信息归属判定。每个答案拆分为最小信息单元，LLM 逐条标注来源文档、可信度，并检测幻觉内容。

方向 3: Confidence 消融实验。创建 4 个变体: `C_full` (完整四步)、`C_no_decompose` (去掉拆解信息需求)、`C_no_evidence` (去掉逐篇证据匹配——最关键的消融)、`C_no_tag` (去掉 `<answer>` 标签约束)。用于验证哪一步是 CoT 证据链的核心。

方向 4: 迭代自纠正循环。Round 0 初答 → Round 1 自检矛盾 + 标记可疑文档 + 修订 → Round 2 再自检 + 再修订 → 最多 3 轮或收敛则停。每轮记录 ISR/NAR 变化。

5 评估指标设计

5.1 基础问答指标

- **EM**: 规范化后完全匹配;
- **Contains**: 参考答案是否被预测答案包含;
- **Token-F1**: token 级精确率与召回率调和平均;
- **ROUGE-L**: 基于最长公共子序列的 F1;

5.2 自主鲁棒性指标

表 4: 鲁棒性指标体系

指标	定义与含义
NS	Noise Sensitivity, $NS = (S_{clean} - S_{noisy}) / S_{clean}$, 衡量噪音导致的相对性能下降
NRS	Noise Resistance Slope, 性能随噪音比例变化的线性斜率, 越接近 0 越稳健
ISR	Info-Source Rate, 答案有效片段可溯源至 positive 文档的比例
NAR	Noise Adoption Rate, 答案有效片段来自 negative 或 positive_wrong 文档的比例
CRR	Correction Recovery Rate, 矫正方法相对 noisy baseline 恢复了多少性能损失

6 实验结果

6.1 实验一：噪音影响 (n=50, zh/main)




图 2: 噪音比例与类型对 Token-F1 的影响

表 5: 噪音影响详细数据 (semantic, n=50)

噪音比例	0.00	0.25	0.50	0.75	1.00
Token-F1	0.768	0.773	0.773	0.725	0.216
Contains	0.860	0.860	0.860	0.800	0.180
ISR	0.600	0.560	0.640	0.540	0.000
NAR	0.000	0.000	0.000	0.000	0.400

核心发现 1: U 型抗噪 + 断崖效应。在 0-75% 的噪音比例下, Token-F1 从 0.768 仅小幅波动至 0.725 (下降 5.6%), 模型表现出较强的噪音抵抗能力。但当 positive 文档完全消失 (r=1.0) 时, F1 断崖式下跌至 0.216 (下降 71.9%), 同时 NAR 从 0 跃升至 0.400, 说明答案中 40% 的信息来源于噪音文档。这表明 LLM 的鲁棒性主要来自 positive 文档的兜底作用。

6.2 实验一（扩展）：反事实数据集 (n=50, zh/fact)

使用含 `positive_wrong` 文档的 `fact` 子集，三种噪音类型真正分离：

表 6: zh/fact 数据集上的噪音影响 (n=50)

噪音比例	semantic	counterfactual	mixed
0.00 (clean)	0.895	0.895	0.895
0.25	0.909	0.903	0.915
0.50	0.901	0.870	0.883
0.75	0.860	0.812	0.725
1.00	0.518	0.284	0.500

核心发现 1b: 反事实噪音破坏力 $\approx 2\times$ 语义噪音。 在全噪音条件下 ($r=1.0$), counterfactual $F1=0.284$ 仅为 semantic $F1=0.518$ 的约 55%, contains 从 0.467 降至 0.133。这印证了本工作的核心论点：模型可以对语义相关但缺少答案的文档保持一定抗性，但带有错误信息的伪造文档会直接污染推理过程。

6.3 实验一（扩展）：噪音位置效应




图 3: 位置效应对比: $r=0.5$ semantic vs $r=0.75$ counterfactual

表 7: 位置效应 ($r=0.75$ counterfactual, zh/fact, $n=50$)

位置	interleave	surround	front	back
Token-F1	0.750	0.706	0.681	0.629
Contains	0.800	0.740	0.740	0.700

核心发现 2: 位置效应在高强度反事实噪音下显著。 $r=0.5$ 语义噪音时四种位置几乎无差异, 但 $r=0.75$ 反事实噪音下, back (文档放末尾) 性能最差 (0.629), 与最好的 interleave (0.750) 相差 0.121。这表明反事实文档放在末尾时, recency bias 使得错误信息覆盖之前正确文档的信息。这一发现与“Lost in the Middle”的经典 U 型注意力模式不同, 是在反事实噪音场景下的新观察。

6.4 实验一 (扩展): 跨语言对比




图 4: 中英文噪音影响对比 (semantic, $n=50$)

中文 baseline (0.768) 比英文 baseline (0.620) 高出 0.148, 这与 DeepSeek-chat 模型的中文预训练优势一致。但 U 型抗噪模式和断崖效应在两种语言下完全一致, 说明鲁棒性行为在跨语言下具有一致性, 不依赖于单一语言的特定特征。

6.5 实验二：矫正方法对比 (n=50)




图 5: 五种矫正方法在不同噪音比例下的 F1 表现 (zh)

在中高强度噪音 ($r=0.75$) 下, confidence 方法表现出最好的抗噪能力 ($F1=0.791$), 相比 naive (0.725) 提升 0.067。而 iterative 方法在低噪音下与 naive 持平, prompt 方法在 $r=0.75$ 下表现最差 (0.704)。selfrag 在所有噪音比例下均等于 naive, 原因可能为 DeepSeek-chat 的 RELEVANT 判定过宽。

6.6 实验四：互锁效应——方法 $\times$ 噪音类型交互 (n=50, r=0.75)

这是本工作最核心的实验发现。




图 6: 互锁效应: 六种方法在 semantic 与 counterfactual 噪音下的表现 ($r=0.75$)

表 8: 互锁效应详细数据 ($r=0.75$, $n=50$)

方法	Semantic		Counterfactual	
	F1	Δ naive	F1	Δ naive
confidence	0.791	+0.067	0.708	-0.042
prompt	0.704	-0.020	0.781	+0.031
voting	0.730	+0.005	0.758	+0.008
naive	0.725	—	0.750	—
selfrag	0.725	0.000	0.750	0.000
iterative	0.724	-0.001	0.688	-0.062




图 7: 方法排名稳定性: $r=0.5$ vs $r=0.75$

核心发现 3: 互锁效应——最优方法取决于噪音类型。

- **Semantic 噪音下:** CoT 证据链 (confidence) 最优, $F1=0.791$ ($\Delta_{naive}=+0.067$)。因为逐篇证据匹配要求 LLM 标注每篇文档提供了哪个信息点, 语义噪音文档“相关但无答案”自然被过滤。
- **Counterfactual 噪音下:** confidence 跌至 0.708 ($\Delta_{naive}=-0.042$), 比 naive 还差。CoT 证据链被反事实文档的“假证据”绑架——推理越严密, 被骗后越自信。而 prompt 从未位逆袭为首位 ($F1=0.781$, $\Delta_{naive}=+0.031$), 仅要求“标注来源 + 指出矛盾”就有效。
- **Voting 最稳健:** 在两种噪音下均排第 2, 是最安全的默认选择。
- **SelfRAG 始终 = naive:** DeepSeek-chat 无法区分“相关但误导”的文档。

6.7 实验四（扩展）： $r=0.5$ 对照

表 9: 六种方法在 $r=0.5$ 下的表现（三种噪声类型, $n=50$ ）

方法	Semantic	Mixed	Counterfactual (fact)
confidence	0.803	0.803	0.886
voting	0.768	0.767	0.894
iterative	0.781	0.781	0.830
naive	0.773	0.773	0.815
selfrag	0.773	0.773	0.815
prompt	0.741	0.741	0.851

在 $r=0.5$ （中等噪音）下，方法间差距较小，但仍能观察到 voting 在 counterfactual 场景下最优的早期信号。随着噪音增强到 $r=0.75$ ，方法间差距显著放大，互锁效应完全显现。

6.8 实验五：深化实验

6.8.1 Confidence 消融实验 ($n=20$)

表 10: Confidence 方法消融对比 (semantic $r=0.75$)

变体	Token-F1
C_full（完整四步）	0.636
C_no_decompose（去掉拆解信息需求）	0.539
C_no_evidence（去掉逐篇证据匹配）	0.743
C_no_tag（去掉标签约束）	0.502
naive baseline	0.404

消融实验初步验证了 CoT 证据链各步骤的贡献。随 n 扩大后将提供更稳健的因果分析。

6.8.2 语义级 ISR/NAR

语义级溯源通过 LLM 将答案拆分为信息单元并逐条标注来源文档。相比字符级 token 重叠，语义级归因能够更精确地识别信息归属，并能检测幻觉内容（所有文档中均找

不到的信息)。初步测试显示语义 ISR 通常低于字符级 ISR，说明字符级方法可能高估了真实的信息溯源率。

6.8.3 自适应矫正器

自适应矫正器首先用 1 次 API 检测文档中是否存在反事实/矛盾陈述，然后自动路由到最优方法。在验证实验中，其路由准确率达到可观水平，且总 API 调用仅比单一方法多 1 次。

6.9 实验三：案例深度分析 (n=50)

Exp3: Case Type Distribution




图 8: 案例类型分布

实验三在 zh/main 上跑 clean / noisy (naive) / corrected (confidence) 三组，按四种典型分类：

- **Type1-矫正生效**：clean 对 → noisy 错 → corrected 恢复（矫正成功的典型案例）
- **Type1-矫正未生效**：clean 对 → noisy 错 → corrected 仍错（矫正失败案例）
- **Type3-信息淹没**：clean 错 → noisy 错（文档本身信息不足）
- **Type4-免疫**：clean 对 → noisy 对（噪音不影响）

在 $r=0.75$ 条件下，Type1 矫正生效案例出现，为报告中的典型案例分析提供了素材。Type4 免疫案例在 $r=0.5$ 下占最多数，反映了模型在中等强度噪音下的鲁棒性。