



面向大模型 RAG 推理场景 噪音文档的鲁棒性推理方法

NLP 实验四 · 题目 8 · 终期实验报告

队长姓名：刘忻洁 队长学号：202300180116

队员姓名：苗怀睿 队员学号：202300300079

2026 年 6 月 26 日

目录

1	课题背景	2
1.1	课目标	2
1.2	核心问题	2
1.3	成果应用价值	2
1.4	主要结论预览	3
2	方法主要框架	3
2.1	总体架构	3
2.2	调用流水线	4
2.3	模块组织	5
3	方法主要技术	5
3.1	噪音注入机制	5
3.2	矫正方法	6
3.3	深化方法详解	6
3.4	核心 Prompt 与代码说明	7
3.5	基础问答指标	7
3.6	自主鲁棒性指标	7
4	实验情况	8
4.1	实验环境与模型配置	8
4.2	数据集下载与预处理	8
4.3	代码运行方式	8
4.4	数据集总览	8
4.5	MobileMem: 自建私人记忆 RAG Benchmark	9
4.6	原始数据 (RGB)	12
4.7	文档池定义	13
4.8	NoiserBench 数据集	13
4.9	后期扩展数据集	13
4.10	自建数据构建引擎 (维基百科扩展, 与 MobileMem 独立)	14
5	实验结果和结论	16
5.1	实验一: 噪音影响分析	16
5.1.1	主矩阵 (zh/main)	16
5.1.2	反事实数据集 (zh/fact)	17
5.1.3	噪音位置效应	18
5.1.4	跨语言对比	19

5.2	实验二：矫正方法对比	20
5.2.1	主实验 (zh/main, semantic)	20
5.2.2	反事实数据集验证 (zh/fact, counterfactual)	20
5.3	实验三：案例深度分析	21
5.3.1	zh/main 与 zh/fact 对比	21
5.3.2	英文案例研究 (en/main)	22
5.4	实验四：互锁效应——方法 $\times$ 噪音类型交互	22
5.4.1	核心实验： $r=0.75$ 互锁矩阵 (zh)	22
5.4.2	$r=0.5$ 对照与排名稳定性	24
5.4.3	英文互锁验证 (en/main)	25
5.5	实验五：深化实验	25
5.5.1	Confidence 消融实验	25
5.5.2	语义级 ISR/NAR	26
5.5.3	自适应矫正器	26
5.5.4	迭代自纠正	27
5.6	跨数据集验证	27
5.7	实验设置	28
5.8	2WikiMultihopQA (英文多跳, $n = 500$)	28
5.8.1	实验一：噪音影响	28
5.8.2	实验二：矫正方法对比	29
5.8.3	反事实子集 (fact, $n = 500$)	30
5.9	MobileMem (calc 子集, $n = 50$)	30
5.10	CmedqaRetrieval (中文医学, $n = 3999$)	33
5.11	跨数据集 Judge 梯度对比	34
5.12	典型案例：噪音如何影响与如何修复	35
5.13	实验结论	35
6	方法局限性讨论	36
6.1	方法边界与不足	36

摘要

本项目研究 RAG 检索文档噪音对推理质量的影响及矫正方法。报告按六部分组织：课题背景、方法框架、主要技术、实验情况、实验结果与结论、方法局限性。实现比例/类型/位置三维度可控噪音注入与 12 种矫正方法，发现 semantic 下 CoT 证据链最优、counterfactual 下 prompt 更稳的互锁效应；在 2Wiki、MobileMem、Cmedqa、BRIGHT 上验证噪音梯度与 CRR 恢复，并提供 HuggingFace 数据集链接、复现命令与 Web 演示平台。

1 课题背景

1.1 课题目标

本项目对应 NLP 实验四题目 8：**面向大模型 RAG 推理场景噪音文档的鲁棒性推理方法**。题目要求关注大模型 RAG 场景中，检索结果可能包含与问题语义相关、但缺少逻辑依赖或会误导答案的上下文文档，进而影响模型问答准确率。项目需要完成以下任务：

- 探究上下文文档对模型问答性能的影响；
- 提出可量化的评估指标；
- 针对具体数据集给出实验结果、结论与分析；
- 结合具体案例分析不同文档对答案的影响；
- 设计矫正机制，例如提示词优化、迭代式生成等；
- 与现有方法进行性能比较，说明方法有效性与局限。

1.2 核心问题

本项目将问题形式化为：给定问题 q 、候选文档集合 $D = \{d_1, \dots, d_n\}$ 和参考答案 a ，当 D 中混入不同类型、比例和位置的噪音文档时，大模型生成答案 $\hat{a}$ 的准确率、证据来源和噪音采纳程度如何变化？此外，不同的矫正机制在不同噪音类型下表现如何？是否存在“互锁效应”——即最优方法取决于噪音类型。

1.3 成果应用价值

- **企业/医疗/法律 RAG**：可控噪音压测 NS/CRR，评估 distractor 风险；
- **自适应路由**：semantic 用 CoT、counterfactual 用 prompt；
- **教学演示**：Web 四阶段界面展示注入噪音与矫正对比；
- **评测协议**：Judge + 多域 benchmark (2Wiki/MobileMem/Cmedqa/BRIGHT)。

1.4 主要结论预览

经过完整的系统实现和 $n=50$ 级别的实验验证，本项目核心发现包括：

- **U 型抗噪 + 断崖效应**：LLM 在 0–75% 噪音下性能几乎不变，但 positive 文档完全消失 ($r=1.0$) 时性能崩溃；
- **互锁效应**：CoT 证据链在语义噪音下最优 ($F1=0.791$)，但在反事实噪音下跌至 0.708 (比 naive 还差)；而简单 prompt 指令在反事实噪音下逆袭为最优 ($F1=0.781$)；
- **位置效应**：在 $r=0.75$ 反事实噪音下，文档放末尾 (back) 的破坏力最大 ($F1=0.629$)，印证 recency bias 在错误信息场景下的危害；
- **跨语言一致性**：英文 baseline (0.620) 显著低于中文 (0.768)，但 U 型抗噪模式跨语言一致；
- **方法深化**：自适应矫正器、语义级 ISR/NAR、消融实验和迭代自纠正循环四项深化工作已实现并验证。

2 方法主要框架

2.1 总体架构

系统由数据层、噪音构造层、推理与矫正层、评估层、可视化与前端层组成。其核心思想是：先从 RGB 数据集中读取问题、答案和文档池，再按实验条件注入噪音，最后调用不同 RAG/矫正方法生成答案并计算指标。




图 1: 系统总体框架图




图 2: 实验流水线逻辑关系

2.2 调用流水线

单次实验的主流程如下：

1. **加载数据**：读取指定语言和子集的 RGB 样本；
2. **注入噪音**：按噪音比例、类型、位置批量构造含噪上下文；
3. **选择方法**：根据实验条件选择 naive、prompt、iterative、confidence、selfrag、voting、adaptive、ablated 消融变体或 iterative_sc；
4. **调用模型**：访问 DeepSeek API，使用 sha1 缓存减少重复调用；
5. **计算指标**：输出基础问答指标与鲁棒性指标；
6. **落盘与可视化**：保存 JSON，生成图表，并同步报告与前端展示。

2.3 模块组织

系统按功能分层组织为以下模块：

表 1: 系统模块划分

模块	功能
数据层	RGB / 2Wiki / MobileMem 等数据加载，统一 RGBRecord 格式
噪音构造层	比例、类型、位置三维度噪音注入
推理与矫正层	12 个矫正方法（含 4 个深化方向）
评估层	EM/Contains/Token-F1/ROUGE-L 基础指标 + NS/NRS/ISR/NAR/CRR 鲁棒性指标
数据构建	MobileMem 记忆图谱构建（图 4）+ 维基 RGB 扩展引擎
实验脚本	4 组核心实验 + 通用运行器
Web 系统	FastAPI 后端 + Vue 3 前端 + Gradio Demo

3 方法主要技术

3.1 噪音注入机制

设最大上下文文档数为 K ，目标噪音比例为 r 。系统从 `positive` 中采样 $K(1-r)$ 个有效文档，从噪音池中采样 Kr 个噪音文档。噪音类型包括：

- **semantic**: 从 `negative` 中采样普通语义噪音；
- **counterfactual**: 从 `positive_wrong` 中采样反事实噪音；
- **mixed**: 同时混合普通噪音和反事实噪音。

噪音位置包括 `front`、`back`、`interleave`、`surround`，用于观察上下文位置偏见对回答的影响。

3.2 矫正方法

表 2: 已实现矫正方法 (共 12 个)

方法	核心思想	API	适用场景
naive	直接拼接文档生成答案	1	基线
prompt (A)	要求识别噪音、标注来源、指出矛盾	1	反事实噪音最优
iterative (B)	逐文档打 high/mid/low $\rightarrow$ 过滤 $\rightarrow$ 生成	$n + 1$	语义噪音候选
confidence (C)	拆解需求 $\rightarrow$ 逐篇标注证据 $\rightarrow$ 综合 $\rightarrow$ 输出	1	语义噪音最优
selfrag	简化 Self-RAG: 相关判定 $\rightarrow$ 生成 $\rightarrow$ 支撑校验	$n + 2$	现有方法对比
voting (D)	3 Persona 独立推理 $\rightarrow$ 多数投票/聚合	3-4	反事实噪音候选
adaptive	自动检测噪音类型 $\rightarrow$ 路由最优方法	2-4	稳健默认选择
iterative_sc	生成 $\rightarrow$ 自检矛盾 $\rightarrow$ 重读 $\rightarrow$ 修订 (3 轮)	3-7	迭代优化
ablated_*	消融变体 (拆解/证据/标签各去掉一环节)	1	因果分析

3.3 深化方法详解

方向 1: 自适应矫正器 (Adaptive Corrector)。首先用 1 次 API 调用快速扫描文档, 检测是否存在明显矛盾/反事实陈述。若检测到 CF (反事实), 路由到 PromptCorrector; 若检测为 CLEAN, 路由到 ConfidenceCorrector (CoT 证据链); 若不确定, 路由到 VotingCorrector 稳健兜底。总 API 调用 2-4 次。

方向 2: 语义级 ISR/NAR。将字符级 token 重叠升级为 LLM 驱动的句子级信息归属判定。每个答案拆分为最小信息单元, LLM 逐条标注来源文档、可信度, 并检测幻觉内容。

方向 3: Confidence 消融实验。创建 4 个变体: C_full (完整四步)、C_no_decompose (去掉拆解信息需求)、C_no_evidence (去掉逐篇证据匹配——最关键的消融)、C_no_tag (去掉 <answer> 标签约束)。用于验证哪一步是 CoT 证据链的核心。

方向 4：迭代自纠正循环。 Round 0 初答 → Round 1 自检矛盾 + 标记可疑文档 + 修订 → Round 2 再自检 + 再修订 → 最多 3 轮或收敛则停。每轮记录 ISR/NAR 变化。

3.4 核心 Prompt 与代码说明

CoT 证据链 (confidence, src/prompts.py): Step1 拆解信息需求; Step2 逐篇标注 Doc[i]→ 信息点; Step3 仅基于证据综合; Step4 输出 <answer>。

Prompt-aware (prompt): 要求识别每篇文档是否真正有用, 只基于有用文档作答, 发现矛盾需标注来源。

核心代码: noise_injector.py ($K(1-r)$ positive + Kr 噪音采样); llm_client.py (LM Studio 调用、token 预算截断、sha1 缓存); rag_pipeline.py + correctors/ (12 种矫正器); evaluator.py (DeepSeek Judge); experiments/_runner.py (条件矩阵、checkpoint)。

3.5 基础问答指标

- **EM:** 规范化后完全匹配;
- **Contains:** 参考答案是否被预测答案包含;
- **Token-F1:** token 级精确率与召回率调和平均;
- **ROUGE-L:** 基于最长公共子序列的 F1;

3.6 自主鲁棒性指标

表 3: 鲁棒性指标体系

指标	定义与含义
NS	Noise Sensitivity, $NS = (S_{clean} - S_{noisy})/S_{clean}$, 衡量噪音导致的相对性能下降
NRS	Noise Resistance Slope, 性能随噪音比例变化的线性斜率, 越接近 0 越稳健
ISR	Info-Source Rate, 答案有效片段可溯源至 positive 文档的比例
NAR	Noise Adoption Rate, 答案有效片段来自 negative 或 positive_wrong 文档的比例
CRR	Correction Recovery Rate, 矫正方法相对 noisy baseline 恢复了多少性能损失

4 实验情况

4.1 实验环境与模型配置

主实验采用生成与 Judge 分离：本地 qwen/qwen3-4b-2507 (LM Studio) + DeepSeek-chat Judge。详见 `.env.example`。

4.2 数据集下载与预处理

表 4: 公开数据集链接与预处理脚本

数据集	HuggingFace	脚本
2Wiki	https://huggingface.co/datasets/xanhho/2WikiMultihopQA	<code>prepare_2wiki.py</code>
Cmedqa	https://huggingface.co/datasets/C-MTEB/CmedqaRetrieval	<code>prepare_cmedqa.py</code>
BRIGHT	https://huggingface.co/datasets/xlangai/BRIGHT	<code>prepare_bright.py</code>
TEMPO	https://huggingface.co/datasets/tempo26/Tempo	<code>prepare_tempo.py</code>
MultiHop-RAG	https://huggingface.co/datasets/yixuantt/MultiHopRAG	<code>prepare_multihop_rag.py</code>
NoiserBench	https://huggingface.co/datasets/Jinyang23/NoiserBench	<code>prepare_noiser_bench.py</code>
MobileMem	内置 <code>data/mobilemem/</code>	<code>prepare_mobilemem.py</code>
RGB	内置 <code>data/rgb/</code>	见 README

4.3 代码运行方式

```
pip install -r requirements.txt && cp .env.example .env
python scripts/prepare_mobilemem.py # 安装 MobileMem 至 data/mobilemem/
python -m src.smoke_test --n 5
python -m experiments.exp1_noise_impact --n 50 --language zh --subset main
python scripts/render_late_stage_figures.py
uvicorn backend.main:app --reload
```

4.4 数据集总览

本项目在中期 RGB 基线之上，逐步接入 9 类公开与自建数据集，覆盖百科多跳、医学检索、长文 hard neg、论坛口语、新闻证据链与私人记忆等多种 RAG 场景。所有语料统一转换为 RGBRecord 格式 (`query / answer / positive / negative / positive_wrong`)，与现有实验流水线完全兼容。图 3 概括各数据集的数据场景与实验分工。

1	2	3	4	5	6	7	8	9
2Wiki MultihopQA	MobileMem	Cmedqa Retrieval	RGB	Noiser Bench	BRIGHT	TEMPO	MultiHop RAG	MIRIAD 5.8M
数据场景 多跳百科问答	数据场景 自建中文购物 记忆图谱	数据场景 中文医学检索 问答	数据场景 中英百科 RAG 问答	数据场景 RAG 噪音鲁棒 性基准	数据场景 英文长文本检 索问答	数据场景 论坛式长文本 问答	数据场景 新闻领域多跳 问答	数据场景 大规模英文医 学问答
实验作用 主实验数据，测 试多文档推理中 的抗噪能力	实验作用 主实验数据，解 决公开数据检索 不必要问题	实验作用 测试专业领域长 文本场景下的纠 错能力	实验作用 用于噪音类型、 位置效应等方法 验证	实验作用 提供多种预标注 噪音，验证方法 泛化能力	实验作用 测试 hard negative 对长 推理链的干扰	实验作用 测试非结构化、 口语化文本下的 鲁棒性	实验作用 分析噪音对多步 证据链的影响	实验作用 作为长生成医学 场景的扩展储备 数据

图 3: 项目使用的 9 类数据集：数据场景与实验作用

中期基线 (RGB)。 RGB 提供中英文主数据与反事实变体，用于验证噪音类型、位置效应与互锁效应等核心方法，是中期实验的主战场。

后期主实验 (2Wiki / MobileMem)。 2WikiMultihopQA 测试多跳百科推理中的抗噪能力；MobileMem 为项目自建 benchmark，模拟「个人全年记忆 → 专属问答助手」的真实落地场景（详见第 4.5 节）。

领域扩展 (Cmedqa / MIRIAD / BRIGHT / TEMPO / MultiHop-RAG)。 Cmedqa 与 MIRIAD 覆盖中英文医学场景；BRIGHT 提供长文 hard negative；TEMPO 与 MultiHop-RAG 分别对应论坛口语与新闻多跳证据链，用于检验方法在非结构化、跨领域语料下的鲁棒性。

噪音基准 (NoiserBench)。 ACL 2025 预标注七类噪音，与 RGB 自建的 semantic / counterfactual 注入机制互补，用于验证方法泛化能力。

4.5 MobileMem：自建私人记忆 RAG Benchmark

MobileMem 是本项目的**核心自建 benchmark**。设计动机是：公开 RAG 数据集（百科、医学、新闻等）的检索需求与真实用户无关——模型只需从通用语料中找答案，无法评估「AI 能否成为某个具体用户的私人助手」。为此，我们构造了一位虚拟用户「赵云澈」2025 全年（Q1-Q4）的**私人生活记忆图谱**：涵盖购物截图、转账记录、群聊、朋友圈、视频/读书/音乐截图等 82 条结构化事件，每条事件含事件 ID、发生时间、长期主题标签与 OCR 结构化字段。

设计目标。 通过追踪同一人物一整年的生活轨迹，让 AI 在 RAG 框架下直接成为「针对该用户所有事务的问答助手」——用户可问「Q2 我买了哪些东西总价多少」「春节给爸妈转了多少钱」等高度个性化问题，模型必须从大量同主题噪音记忆中精准检索并聚合推理。

数据规模与划分。 MobileMem 共 240 条 QA (120 calc + 120 noncalc)，每条样本固定 4 条 positive；negative 为 20-80 条同用户其他真实记忆（非反事实篡改，策略为 real_cross_event_non_contradictory_non_supporting）：

- **calc** (计算类): 问题指定若干事件, 要求跨事件聚合计算 (求和、最值差、计数等), 如「Q2 四个指定购物事件实际价格的最大值与最小值之差」;
- **noncalc** (检索类): 从指定时间窗口的记忆中检索单一事实, 如「2025 Q1 某次网购的商品名称」。

图 4 概括 MobileMem 从记忆图谱到评测的完整流程。左侧为**数据构建**: 原始 OCR 记忆经字段解析后构造 query/answer 与文档池; 购物类事件额外抽取商品、店铺、价格、下单时间, 枚举 4 个目标事件并生成 calc/noncalc 两类问题, 目标事件标注为 positive、同用户其他记忆标注为 negative, 最终统一写入 RGBRecord 格式(data/mobilemem/zh_calc.json、zh_noncalc.json, 由 prepare_mobilemem.py 安装)。右侧为**评测流水线**: 与项目主实验一致——按比例/类型/位置注入 semantic 噪音 → Prompt 拼接 → naive / prompt / confidence / voting / adaptive 等矫正方法 → DeepSeek Judge 与 NS/NRS/ISR/NAR/CRR 指标 → 结果可视化。




图 4: MobileMem 数据构建与噪音评测流水线

构建步骤 (对应图 4 左侧):

1. **原始记忆采集**: 按季度编排虚拟用户生活事件, 将截图类记忆 OCR 为结构化文本;
2. **字段解析与标准化**: 统一事件 ID、发生时间、长期主题、记录类型 (购物/转账/群聊等);
3. **构造 query 与 answer**: 按月份或事件枚举生成自然语言问题与参考答案;
4. **购物记忆专项分支**: 抽取价格等字段, 枚举 4 个目标事件, 分别生成 calc (聚合计算) 与 noncalc (单事实检索);
5. **文档池标注**: 目标事件记忆 → positive; 同用户其他真实记忆 → negative;
6. **格式对齐**: 输出 RGBRecord, 与 RGB / 2Wiki 等数据集共用同一实验脚本。

图 5 展示 calc 样本 #370002: 问题限定 Q2 四个购物事件, positive 为 4 条对应 OCR 记忆 (含实际价格), negative 为 76 条同季度无关记忆; 推理路径为 Event 41/43/44/47 $\rightarrow 469-198=271$ 元。



样本 120

#370000 求和 · 2025年第2季度

#370001 最大值 · 2025年第3季度

#370002 范围 · 2025年第2季度

#370003 范围 · 2025年第2季度

#370004 最大值 · 2025年第3季度

#370005 范围 · 2025年01月

#370006 最大值 · 2025年第1季度

#370007 范围 · 2025年第2季度

#370008 范围 · 2025年第2季度

#370009 范围 · 2025年01月

#370010 求和 · 2025年第2季度

#370011 最小值 · 2025年第2季度

#370012 最小值 · 2025年01月

#370013 范围 · 2025年第2季度

#370014 求和 · 2025年第2季度

#370015

#370002 范围 · 2025年第2季度 实际价格

在2025年第2季度的私人记忆中,只统计以下4个事件: 2025-05-31 10:00 《端午节线上购买粽子礼盒给父母与岳父母》、2025-06-02 18:00 《端午节假期楼下商圈现场选购凉席和夏被》、2025-06-05 20:00 《端午节后为父母补买保健品的理性与情感拉扯》、2025-06-20 20:00 《生日后为自己添置新键盘和显示器的网购决策》。根据这些事件各自的购物截图,实际价格的最大值和最小值相差多少?

答案: 271元

推理路径 4 个目标事件

41 端午节线上购买粽子礼盒给父母与岳父母 218元

43 端午节假期楼下商圈现场选购凉席和夏被 468元

44 端午节后为父母补买保健品的理性与情感拉扯 198元

47 生日后为自己添置新键盘和显示器的网购决策 469元

Positive (4)

P1 发生时间: 2025-06-02 18:00
长截事件: 端午节假期楼下商圈现场选购凉席和夏被
记录类型: 购物截图
商品名称: 可水洗冰丝凉席三件套+夏凉被套装
店铺: 大邑之家家纺旗舰店
实际价格: 468元
下单时间: 2025-06-02 18:25:00
评分: 5

P3 记忆证据: MobileMem 私人生活记录
事件ID: 44
事件名称: 端午节后为父母补买保健品的理性与情感拉扯
发生时间: 2025-06-05 20:00
长截事件: 端午节后为父母补买保健品的理性与情感拉扯
记录类型: 购物截图
商品名称: 伟思特 多种维生素矿物质片 60片*2瓶
店铺: 乐信医药官方旗舰店
实际价格: 198元
下单时间: 2025-06-05 21:12:00
评分: 5

P4 记忆证据: MobileMem 私人生活记录
事件ID: 47
事件名称: 生日后为自己添置新键盘和显示器的网购决策
发生时间: 2025-06-20 20:00
长截事件: 生日后为自己添置新键盘和显示器的网购决策
记录类型: 购物截图
商品名称: 87键热插拔机械键盘 TTC静音红轴
店铺: KeyShine机械键盘旗舰店

Negative (76)

N1 发生时间: 2025-05-14 20:00
长截事件: 第二季度技术学习上课程投入与坚持
记录类型: 购物截图
商品名称: A5网络学习笔记本套装 (四色分装)
店铺: 晨光办公文具旗舰店
实际价格: 39.9元
下单时间: 2025-05-10 21:12:39
评分: 5

N2 记忆证据: MobileMem 私人生活记录
事件ID: 50
事件名称: 盛夏周末和室友提前在线买地票的选择
发生时间: 2025-07-05 10:00
长截事件: 盛夏周末和室友提前在线买地票的选择
记录类型: 购物截图
商品名称: 深圳上观体育中心羽毛球场地预订 (含淋浴) 2小时周末档
店铺: 上观体育中心官方旗舰店
实际价格: 148元
下单时间: 2025-07-05 10:06:32
评分: 5

N3 记忆证据: MobileMem 私人生活记录
事件ID: 23
事件名称: 春季清仓假期前理性回乡归程行程讨论
发生时间: 2025-03-24 20:10
长截事件: 春季清仓假期前理性回乡归程行程讨论
记录类型: 购物截图
商品名称: 康乐佳途车震类短途长沙 (代购服务)
店铺: 畅行旅行票务服务店

图 5: MobileMem calc 样本 #370002: Q2 购物记忆检索与跨事件价格差计算

图 6 展示 Web 演示平台对 noncalc 样本 #371000 的交互式评测链路: 检索池 (4 positive + 26 negative) $\rightarrow$ semantic 噪音注入 ($r = 0.70$) $\rightarrow$ 可选 CRAG-style 文档预过滤 $\rightarrow$ 矫正器生成与 Judge 评测。主线批量实验 (图 4 右侧) 不依赖该预过滤步骤, 直接调用 12 种矫正方法。




图 6: MobileMem noncalc 样本 #371000: Web 演示平台四阶段评测流水线

与公开数据的差异。公开数据集检索的是「世界知识」，MobileMem 检索的是「个人历史」——negative 文档与 positive 高度同域（同一人物、同一季度、同类购物/社交记录），语义噪音干扰远强于百科场景，更能暴露 RAG 在高相关噪音下的脆弱性。本集采用 DeepSeek Judge 作为主指标（短答案/计算类更适合 LLM 判别）。

4.6 原始数据（RGB）

项目初期使用 RGB 数据集作为公开问答与候选文档来源，包含中英文主数据、反事实数据、信息整合数据和 refine 数据：

表 5: RGB 数据文件与用途

数据文件	语言	样本数	用途
zh.json, en.json	中/英	各 300	主问答数据，含 positive 与 negative 文档池
zh_fact.json, en_fact.json	中/英	各 100	反事实噪音数据，额外含 positive_wrong 和 fakeanswer
zh_int.json, en_int.json	中/英	各 100	信息整合类问题，用于后续跨文档推理扩展
zh_refine.json, en_refine.json	中/英	各 300	refine 变体，用于后续泛化验证

4.7 文档池定义

RGB 数据天然给出了适合本题的三类文档池：

表 6: 三类文档池与噪音含义

字段	实验含义	使用方式
positive	支持正确答案的有效文档	构造 clean RAG 上下文，计算 ISR
negative	语义相关但不能支持答案的普通噪音文档	模拟检索噪音，计算 NAR
positive_wrong	表面相关但指向错误答案的反事实文档	模拟更强误导性噪音，测试矫正机制

4.8 NoiserBench 数据集

项目额外引入 NoiserBench (ACL 2025) 作为补充评测数据集，提供七类预标注噪音 (semantic、cause_effect、counterfactual_answer 等)，与 RGB 自建的 semantic/counterfactual 注入机制互补。NoiserBench 涵盖三类推理跳数：

表 7: NoiserBench 子集概览

类别	子集	特点
Single-hop	NQ, RGB	单跳检索问题，标注语义噪音与反事实噪音
Multi-hop (explicit)	HotpotQA, 2WikiMQA, Bamboogle	多跳显式推理
Multi-hop (implicit)	StrategyQA, TempQA	多跳隐式推理 (常识/时间)
Mix-hop	PriorQA	混合跳数，测试模型的推理泛化能力

数据统一转换为 RGBRecord 格式，与现有实验流水线完全兼容。

4.9 后期扩展数据集

在中期 RGB 基线之外，项目通过 `scripts/prepare_*.py` 接入了图 3 所列公开/自建数据集，用于验证互锁效应与矫正方法的可迁移性：

表 8: 后期扩展数据集概览

数据集	语言	main 规模	实验规模	特点
2WikiMultihopQA	en	5000	n=500	多跳 Wikipedia, 同 context hard neg
CmedqaRetrieval	zh	3999	n=3999	中文医学 检索, 长 答案
MIRIAD-5.8M	en	5.8M	n=100	英文医学 长生成
MobileMem (自建)	zh	120×2	n=50	全年私人 记忆图谱, calc/noncalc
BRIGHT / TEMPO / MultiHop-RAG	en	749–2255	sanity n=100	长文 hard neg / 论 坛 / 新闻 证据链
NoiserBench	en	子集各异	试跑 n=2	ACL'25 七类预标 注噪音

各数据集均提供 **main** 子集; 2Wiki、Cmedqa、BRIGHT 等另含 **fact** 子集 (脚本自动构造 **positive_wrong**), 用于 counterfactual 实验。MobileMem 以 semantic 噪音为主, 详情见第 4.5 节。

4.10 自建数据构建引擎 (维基百科扩展, 与 MobileMem 独立)

由于公开数据集的规模有限, 且问题对于现有大模型过于简单, 为扩展数据覆盖面、验证方法的真实表现, 项目另设计了一套基于维基百科爬取和 DeepSeek 生成的 RGB 扩展引擎 (MobileMem 记忆图谱构建见第 4.5 节, 二者流程相互独立)。引擎支持从任意关键词出发, 全自动生成符合 RGB 格式的高质量 RAG 鲁棒性测试数据。




图 7: 数据构建引擎流程图

构建流程分为五个阶段：

- 关键词输入**：用户在前端输入主题关键词（如”量子力学””基因编辑”）；
- 文档爬取**：多策略搜索中文维基百科 API，扩展关键词变体（原词、分词、”原理”、”历史”后缀），获取 20+ 篇高质量文档；
- LLM 生成**：调用 DeepSeek API，基于真实文档生成一条完整测试数据——含有难度的问题、正确答案、5 篇支撑文档、3 篇反事实文档和 3 个错误答案；
- RGB 格式组装**：将生成结果对齐到 positive / negative / positive_wrong / fakeanswer 标准字段，与 RGB 数据集格式完全一致；
- 质量检查**：自动验证字段完整性与格式合规性。

引擎后端通过 FastAPI SSE 接口实时推送生成进度，前端提供可视化流水线界面，支持一键生成与实时预览。生成的数据直接用于实验流水线。图 8 展示了一条以”黑洞”为关键词生成的测试数据案例，包含问题、正确答案、4 篇支撑文档、5 篇语义噪音文档和 2 篇反事实文档（红色标注处为被篡改的关键信息）。

Question

基于黑洞的形成、观测和理论发展，请分析为什么黑洞长期以来被认为是数学上的好奇，直到20世纪60年代后才被接受为天体物理实体？

Answer

黑洞长期被视为数学好奇，因为史瓦西解（1916）缺乏物理解释，芬克尔斯坦1958年才解释为不可逃逸区域。20世纪60年代后，中子星发现（1967）激发兴趣，理论工作显示黑洞是广义相对论的一般预测，随后通过X射线、恒星轨道和引力波观测证实。

支撑文档 Positive 4 篇

P0 黑洞是一种天体，因极高密度产生极大引力，所有粒子与光无法逃逸。广义相对论预测足够紧密的质量可扭曲时空形成黑洞...

P1 1916年史瓦西发现第一个广义相对论精确解，1958年芬克尔斯坦首次将其解释为无法逃逸的空间区域...

P2 20世纪60年代理论工作显示黑洞是广义相对论一般预测。1967年贝尔发现中子星，激发了人们对引力坍缩致密天体的兴趣...

P3 观测证据在20世纪后期逐步积累：X射线喷流、恒星轨道确定质量、2016年LIGO直接探测到引力波...

噪音文档 Negative 5 篇

N0 黑洞信息悖论是量子力学与广义相对论结合时的难题。1970年代霍金发现黑洞会发出霍金辐射...

N1 恒星黑洞是大质量恒星引力坍缩后形成的黑洞，质量五至数十倍太阳。目前已知最大质量恒星黑洞 15.65 ± 1.45 倍...

N2 超大质量黑洞质量是太阳的 10^6 至 10^9 倍。一般相信所有大型星系中心都存在超大质量黑洞...

N3 霍金（1942—2018），英国理论物理学家，贡献包括彭罗斯-霍金奇点定理及霍金辐射理论预测...

N4 黑洞热力学发展于1970年代，将热力学定律应用于黑洞研究，暗示广义相对论与量子理论的深刻联系...

反事实文档 2 篇

CF0 ...史瓦西1916年发现解，1958年芬克尔斯坦解释。直到**20世纪80年代**，贝尔伯奈尔发现中子星才激发兴趣...

CF1 ...20世纪60年代理论工作显示黑洞是一般预测。1967年，**约翰·米歇尔**发现中子星，激发了引力坍缩致密天体兴趣...

篡改策略: CF0 将年份 60年代→80年代; CF1 将人物 贝尔伯奈尔→约翰·米歇尔

图 8: 数据引擎生成案例：关键词”黑洞”→ 自动构造 RAG 鲁棒性测试数据

5 实验结果和结论

中期 RGB 实验在 $n=50$ 级别运行，生成端使用 DeepSeek-chat；后期跨数据集实验采用本地 qwen3-4b (LM Studio) 生成 + DeepSeek Judge 评测，sha1 缓存减少重复调用。完整覆盖 zh/en 双语言 $\times 5$ 组实验 $\times 17$ 个独立配置。

5.1 实验一：噪音影响分析

5.1.1 主矩阵 (zh/main)




图 9: 噪音比例与类型对 Token-F1 的影响 (zh/main)

表 9: 噪音影响详细数据 (semantic, zh/main, $n=50$)

噪音比例	0.00	0.25	0.50	0.75	1.00
Token-F1	0.768	0.773	0.773	0.725	0.216
Contains	0.860	0.860	0.860	0.800	0.180
ISR	0.600	0.560	0.640	0.540	0.000
NAR	0.000	0.000	0.000	0.000	0.400

发现 1: U 型抗噪 + 断崖效应。在 0-75% 噪音下 F1 从 0.768 仅小幅波动至 0.725 (-5.6%)。但当 positive 文档完全消失 ($r=1.0$) 时 F1 断崖式下跌至 0.216 (-71.9%)，同

时 NAR 跃升至 0.400。LLM 的鲁棒性主要来自 positive 文档的兜底作用，而非模型自身对噪音的识别能力。

5.1.2 反事实数据集 (zh/fact)

使用含 `positive_wrong` 文档的 fact 子集，三类噪音 (semantic / counterfactual / mixed) 得以真正分离。fact 子集提供了更高质量的 positive 文档和专门的 counterfactual 噪音来源，可更清晰观察不同类型噪音对模型推理的差异化影响。




图 10: zh/fact 数据集上三种噪音类型随噪音比例的性能变化

表 10: zh/fact 数据集上的噪音影响详细数据 (n=50)

噪音比例	semantic		counterfactual		mixed
	F1	Contains	F1	Contains	
0.00 (clean)	0.895	0.960	0.895	0.960	0.895
0.25	0.909	0.960	0.903	0.940	0.915
0.50	0.901	0.940	0.870	0.940	0.883
0.75	0.860	0.940	0.812	0.840	0.725
1.00	0.518	0.500	0.284	0.060	0.500

从图中可以清晰观察到三类噪音的差异化表现：

- **Semantic 噪音 (蓝线)**: 在 0-75% 比例下性能稳定 (F1 始终 ≥ 0.86), 仅 $r=1.0$ 时跌至 0.518。语义相关但不直接支持答案的文档对模型推理干扰有限, 模型展现出 U 型抗噪特征;
- **Counterfactual 噪音 (橙线)**: 呈单调下降趋势。 $r=0.25$ 时 $F1=0.903$, $r=0.50$ 降至 0.870, $r=0.75$ 降至 0.812。 $r=1.0$ 时崩盘至 0.284, Contains 仅 0.060——模型几乎完全被反事实文档误导。下降曲线为近线性而非 U 型, 表明反事实文档的破坏力随比例线性累积;
- **Mixed 噪音 (绿线)**: 介于两者之间, $r=1.0$ 时 $F1=0.500$ (高于 counterfactual 的 0.284 但略低于 semantic 的 0.518)。

发现 2: 反事实噪音破坏力显著高于语义噪音。 $r=1.0$ 时 counterfactual $F1=0.284$ 仅为 semantic $F1=0.518$ 的约 55%, Contains 从 0.960 暴跌至 0.060——即便答案仍然部分包含在上下文中, 模型也不再输出正确答案。带有错误信息的伪造文档直接污染推理过程, 且随噪音比例增加呈持续衰减趋势 (非 U 型模式), 说明模型对看起来像真的的错误信息缺乏免疫力。

5.1.3 噪音位置效应




图 11: 位置效应对比: $r=0.5$ semantic vs $r=0.75$ counterfactual

表 11: 位置效应 ($r=0.75$ counterfactual, zh/fact, $n=50$)

位置	interleave	surround	front	back
Token-F1	0.750	0.706	0.681	0.629
Contains	0.800	0.740	0.740	0.700

发现 3: recency bias 在反事实噪音下有害。 $r=0.5$ 语义噪音时四种位置几乎无差异。但在 $r=0.75$ 反事实噪音下 back 性能最差 (0.629)，与最好的 interleave (0.750) 相差 0.121。这表明反事实文档放在末尾时，recency bias 使错误信息覆盖正确文档的信息。

5.1.4 跨语言对比




图 12: 中英文噪音影响对比 (semantic, $n=50$)

中文 baseline (0.768) 比英文 baseline (0.620) 高 0.148，与 DeepSeek-chat 的中文预训练优势一致。但 U 型抗噪模式和断崖效应在两种语言下完全一致，鲁棒性行为具有跨语言一致性。

5.2 实验二：矫正方法对比

5.2.1 主实验 (zh/main, semantic)




图 13: 五种矫正方法在不同噪音比例下的 F1 表现 (zh/main)

中高强度噪音 ($r=0.75$) 下, confidence 方法 $F1=0.791$ 相比 naive (0.725) 提升 0.067。prompt 方法最差 (0.704)。selfrag 在所有噪音比例下均等于 naive, DeepSeek-chat 的 RELEVANT 判定过宽。

5.2.2 反事实数据集验证 (zh/fact, counterfactual)

表 12: 五种矫正方法在 counterfactual 噪音下的表现 (zh/fact, $n=50$)

方法	$r=0.00$	$r=0.25$	$r=0.50$	$r=0.75$
naive	0.895	0.903	0.870	0.812
prompt	0.890	0.901	0.876	0.813
iterative	0.895	0.893	0.871	0.750
confidence	0.901	0.930	0.877	0.712
selfrag	0.895	0.903	0.870	0.812

发现 4: 互锁效应跨数据集验证。 confidence 在低噪音下最佳 ($r=0.25$ 时 $F1=0.930$), 但在 $r=0.75$ 时崩溃至 0.712 (低于 naive 的 0.812)。prompt 在 $r=0.75$ 下最稳定 (0.813), 证实简单指令在反事实场景的有效性。

5.3 实验三：案例深度分析

实验三通过 clean / noisy (naive) / corrected (confidence) 三组对比，将案例按以下四种类型分类：

- **Type1-生效**：clean 对 → noisy 错 → corrected 恢复
- **Type1-未生效**：clean 对 → noisy 错 → corrected 仍错
- **Type3-信息淹没**：clean 错 → noisy 错
- **Type4-免疫**：clean 对 → noisy 对

5.3.1 zh/main 与 zh/fact 对比




图 14: zh/main 案例类型分布与性能恢复

zh/main 上 $r=0.5$ 和 $r=0.75$ 下 Type4（免疫）占多数，confidence 矫正效果随噪音增强逐渐显著。 $r=1.0$ 时矫正基本无效。




图 15: zh/fact 案例类型分布与性能恢复

表 13: zh/fact 案例类型分布 (三组 ratio, 每组 pick=20)

ratio	Type1-生效	Type1-未生效	Type3-淹没	Type4-免疫
0.50	1 (5%)	0 (0%)	2 (10%)	17 (85%)
0.75	0 (0%)	1 (5%)	2 (10%)	17 (85%)
1.00	3 (15%)	17 (85%)	0 (0%)	0 (0%)

发现 5: fact 数据集高度抗噪。 fact 的 positive 文档质量更高: $r=0.5$ 和 $r=0.75$ 下 85% 案例为 Type4 (免疫)。但 $r=1.0$ (positive 文档全消失) 时断崖效应再次出现: 85% 案例矫正未生效。

5.3.2 英文案例研究 (en/main)




图 16: en/main 案例类型分布与性能恢复

英文 baseline ($F1=0.601$) 低于中文, 但 confidence 矫正同样释放正向效果, 矫正方法的跨语言有效性得到验证。

5.4 实验四: 互锁效应——方法 $\times$ 噪音类型交互

5.4.1 核心实验: $r=0.75$ 互锁矩阵 (zh)

这是本工作最核心的实验发现。




图 17: 互锁效应: 六种方法在 semantic 与 counterfactual 噪音下的表现 ($r=0.75$)

表 14: 互锁效应详细数据 ($r=0.75$, $n=50$)

方法	Semantic		Counterfactual	
	F1	Δ naive	F1	Δ naive
confidence	0.791	+0.067	0.708	-0.042
prompt	0.704	-0.020	0.781	+0.031
voting	0.730	+0.005	0.758	+0.008
naive	0.725	—	0.750	—
selfrag	0.725	0.000	0.750	0.000
iterative	0.724	-0.001	0.688	-0.062

5.4.2 $r=0.5$ 对照与排名稳定性

表 15: 六种方法在 $r=0.5$ 下的表现（三种噪声类型, $n=50$ ）

方法	Semantic	Mixed	Counterfactual (fact)
confidence	0.803	0.803	0.886
voting	0.768	0.767	0.894
iterative	0.781	0.781	0.830
naive	0.773	0.773	0.815
selfrag	0.773	0.773	0.815
prompt	0.741	0.741	0.851




图 18: 方法排名稳定性: $r=0.5$ vs $r=0.75$

发现 6: 互锁效应——最优方法取决于噪音类型。

- **Semantic 噪音:** CoT 证据链 (confidence) 最优, $F1=0.791$ ($\Delta_{naive}=+0.067$)。逐篇证据匹配自然过滤不相关文档;
- **Counterfactual 噪音:** confidence 跌至 0.708 (比 naive 还差), CoT 被”假证据”绑架——推理越严密被骗后越自信; 而 prompt 从末位逆袭为首位 ($F1=0.781$);
- **Voting 最稳健:** 两种噪音下均排第 2, 是最安全的默认选择;
- **SelfRAG 始终 = naive:** DeepSeek-chat 无法区分”相关但误导”的文档。

在 $r=0.5$ 下方法差距较小, 噪音增强到 $r=0.75$ 后互锁效应完全显现。

5.4.3 英文互锁验证 (en/main)

表 16: 英文 semantic 噪音下的方法对比 (en/main, $r=0.75$, $n=50$)

方法	Token-F1	Contains	ISR	NAR
confidence	0.678	0.60	0.671	0.082
iterative	0.628	0.60	0.778	0.039
prompt	0.626	0.58	0.634	0.091
voting	0.621	0.60	0.611	0.055
naive	0.601	0.56	0.614	0.084
selfrag	0.601	0.56	0.614	0.084

英文语义噪音下 confidence 同样最优 ($F1=0.678$)，排名与中文一致，验证互锁效应跨语言稳定。英文 baseline (0.601) 显著低于中文 (0.725)。

5.5 实验五：深化实验

5.5.1 Confidence 消融实验

表 17: Confidence 方法消融对比 (semantic $r=0.75$, $n=20$)

变体	zh F1	en F1
naive baseline	0.685	0.558
confidence (正常调用)	0.683	0.585
C_full (消融对照版)	0.683	0.534
C_no_decompose (去掉拆解)	0.704	0.561
C_no_evidence (去掉证据)	0.697	0.554
C_no_tag (去掉标签)	0.679	0.550

发现 7: 英文消融全负——CoT 证据链的跨语言不对称性。

- 中文：去掉拆解需求反而提升 ($0.704 > 0.683$)，说明中文下 CoT 过度拆解可能引入噪声。去掉标签约束导致最严重下降 (0.679)， $\langle answer \rangle$ 标签对中文输出约束至关重要；

- **英文**: 所有消融变体均低于或仅持平 naive baseline (0.558)。confidence 正常调用可获 +4.8% 增益 (0.585), 但消融版的 C_full (0.534) 反而比 naive 还差 4.3%。这表明: 英文下 CoT 证据链的每一步都对最终质量有贡献, 任何一个环节的 prompt 质量下降都会导致输出崩溃;
- **中英差异**: 中文即便消融部分步骤仍可保持 $F1 > 0.67$ (远高于 naive 0.685); 英文消融后 F1 全部跌落至 0.53–0.56 区间, 接近甚至低于 naive, 反映出英文场景下 CoT 推理对 prompt 质量高度敏感。

5.5.2 语义级 ISR/NAR

语义级溯源将字符级 token 重叠升级为 LLM 驱动的信息归属判定。5 个英文样本测试中语义 ISR 均为 1.0, 无幻觉内容检出。语义 ISR 通常低于字符级 ISR, 表明字符级方法可能高估信息溯源率。

5.5.3 自适应矫正器

设计动机: 实验四揭示了互锁效应——confidence 在语义噪音下最优 ($F1=0.791$) 但在反事实噪音下崩溃 (0.708, 比 naive 还差), 而 prompt 在反事实噪音下逆袭 (0.781)。一个理想系统应能自动识别噪音类型并路由到最优方法。

三阶段架构:

1. **噪音检测器** (1 次 API, max_tokens=16, temperature=0): 将文档截断至每篇 1200 字符 → LLM 扫描是否存在反事实/矛盾陈述 → 输出 CF / CLEAN。使用独立系统提示和独立 max_tokens (16 vs RAG 的 512), 通过缓存键隔离避免与主 RAG 调用碰撞;
2. **多级解析**: 精确匹配 CF/CLEAN → 中文语义匹配 (反事实/有矛盾/虚构 → CF; 无矛盾/一致 → CLEAN) → 兜底 UNCERTAIN;
3. **路由**: CF → PromptCorrector (标注来源 + 指出矛盾, 反事实下 $F1=0.781$); CLEAN → ConfidenceCorrector (CoT 证据链, 语义下 $F1=0.791$); UNCERTAIN → VotingCorrector (多 Persona 稳健兜底)。

验证结果 (zh/fact, $r=0.75$, $n=30$):

表 18: 自适应矫正器验证 (zh/fact, $r=0.75$, $n=30$)

方法	Semantic F1	Counterfactual F1	路由分布
naive	0.822	0.738	—
confidence (semantic 最优)	0.863	0.713	—
prompt (counterfactual 最优)	—	0.763	—
adaptive	0.831	0.763	CF=11/19 (sem) / CF=30/0 (cf)

发现 8：自适应有效避免最差情况。

- **Semantic 噪音**：adaptive F1=0.831, +1.1% vs naive (0.822), 略低于 confidence (0.863)。19/30 样本正确路由到 confidence, 11/30 检测器过于敏感误判为 CF；
- **Counterfactual 噪音**：adaptive F1=0.763, 等于最优方法 prompt (0.763), +3.4% vs naive (0.738)。30/30 全部正确检测为 CF 并路由到 prompt, 完美避开了 confidence 的崩溃 (0.713)；
- **关键价值**：adaptive 不会选择”错误”的方法。即使用 confidence 在 CF 下崩溃 6.9%, adaptive 始终 $\geq$ naive, 在最危险的反事实场景下与已知最优方法持平。

5.5.4 迭代自纠正

英文 $n=10$ 测试中 iterative_sc 的 F1=0.375 低于 naive baseline 的 0.492, 所有样本均未达成收敛。当前实现仍在优化中, 主要挑战在于大模型自检的矛盾判断准确率不足。

5.6 跨数据集验证

中期实验 (§6) 在 RGB 上揭示了 U 型抗噪、互锁效应与自适应路由等核心规律。后期工作在**相同评估框架**下扩展至多领域数据集, 回答: 这些规律是否可迁移? 不同语料形态 (多跳、医学、OCR 记忆) 下最优矫正策略是否一致?

5.7 实验设置

表 19: 后期实验与中期实验的设置差异

维度	中期 (§6 主实验)	后期 (本节)
主数据集	RGB zh/en	2Wiki、Cmedqa、MobileMem 等
生成模型	DeepSeek-chat (API)	本地 qwen3-4b (LM Studio) + DeepSeek Judge
主指标	Token-F1 / Contains	DeepSeek Judge Score (全部后期数据集)
方法子集	5-6 种全量对比	naive / prompt / confidence / voting (性价比子集)
噪音配置	全比例梯度 + 三类型	semantic, $r \in \{0, 0.5, 0.75\}$

说明: 中期 RGB 结果仍作为**主文核心结论**; 后期结果用于跨数据集对照, 表头均标注样本规模 n 与指标类型, 避免与中期 DeepSeek 端到端数值直接混比。

5.8 2WikiMultihopQA (英文多跳, $n = 500$)

5.8.1 实验一: 噪音影响




图 19: 2Wiki 上 naive 方法的 semantic 噪音梯度 ($n = 500$)

2Wiki 上 naive 基线随 semantic 噪音**单调下降**: $r = 0$ 时 Judge=0.720, $r = 0.75$ 时 0.580 (-19.4%), $r = 1.0$ 时跌至 0.180 (-75.0%)。说明多跳 hard negative 场景下, positive 文档仍是答案质量的决定性因素。

5.8.2 实验二：矫正方法对比




图 20: 2Wiki 上多方法矫正对比 (semantic, $n = 500$)




图 21: 2Wiki 各方法随噪音比例变化 (DeepSeek Judge Score)

在 $r = 0.75$ 高强度 semantic 噪音下，各方法 DeepSeek Judge Score 为: confidence=0.620 > naive=0.580 > voting=0.560 > prompt=0.540。这与 RGB 上语义噪音下 CoT 证据链最优的互锁模式一致；confidence 相对 naive 有明显恢复。




图 22: 2Wiki Exp4: $r = 0.75$ semantic 下六方法对比 ($n = 500$)

5.8.3 反事实子集 (fact, $n = 500$)

2Wiki fact 子集由脚本从 hard negative 自动构造 positive_wrong，质量弱于 RGB 原版实体替换。naive 在 counterfactual 噪音下 F1 整体偏低 ($r = 0$ 仅 0.093)，但仍观察到 $r = 1.0$ 断崖 (0.012)，与主集规律一致。

5.9 MobileMem (calc 子集, $n = 50$)

MobileMem 为项目自建 benchmark (第 4.5 节)，证据来自虚拟用户 2025 全年私人生活记忆的 OCR 结构化文本。calc 子集要求跨多条指定事件聚合计算，negative 与 positive 同属个人记忆、语义高度相近，更能检验 RAG 在「个人助手」场景下的抗噪能力。本集采用 DeepSeek Judge 作为主指标。




图 23: MobileMem calc: naive Judge Score 随 semantic 噪音变化 ($n = 50$)




图 24: MobileMem calc: 四方法矫正对比 (Judge Score, $n = 50$)

表 20: MobileMem calc 关键结果 (Judge Score / Judge Correct@ $r = 0.75$)

方法	clean ($r = 0$)	$r = 0.5$	$r = 0.75$	NS
naive	0.808 / 72%	0.764 / 66%	0.440 / 18%	0.255
confidence	0.804 / 68%	0.772 / 64%	0.536 / 30%	0.187
prompt	0.720 / 58%	0.724 / 60%	0.468 / 22%	0.172
voting	0.812 / 72%	0.704 / 58%	0.468 / 22%	0.278

发现 9: OCR 记忆场景下 confidence 在高噪音时优于 naive。 $r = 0.75$ 时 confidence Judge=0.536, 比 naive (0.440) 高 21.8%, Judge 正确率 30% vs 18%。voting 在 clean 时最优 (0.812), 但高噪音下与 prompt 同为 0.468, API 成本不值得。




图 25: MobileMem 四方法鲁棒性雷达图 (NS/NRS/ISR/NAR)

5.10 CmedqaRetrieval (中文医学, $n = 3999$)




图 26: Cmedqa 全量矫正对比 (semantic, $n = 3999$)

医学长答案场景 baseline Judge 整体较低 (naive clean=0.580)。confidence 在噪音下仍保持优势： $r = 0.75$ 时 Judge=0.580，高于 naive (0.460)，说明 CoT 证据链在专业术语密集文本中有一定纠错能力。

5.11 跨数据集 Judge 梯度对比




图 27: RGB / 2Wiki / Cmedqa 上 naive 的 Judge Score 噪音曲线 ($n = 50-500$)




图 28: 2Wiki / Cmedqa 上 naive DeepSeek Judge 噪音曲线

跨数据集对比显示数据集难度与抗噪形态差异显著:

- **RGB**: clean Judge=0.912, $r = 0.75$ 仍保持 0.784 (NS=0.112), 抗噪最强;
- **2Wiki**: Judge 在 0.58 附近近乎平坦 (NS $\approx$ 0), F1 曲线则呈 RGB 式断崖;
- **Cmedqa**: prompt clean=0.632 最高, 但 $r = 0.5$ 后跌至 0.468 (NS=0.260), 说明简单指令在医学场景 clean 表现好、噪音下脆弱。

5.12 典型案例：噪音如何影响与如何修复

表 21: 代表性案例 (semantic 噪音)

案例	噪音影响	修复方式
RGB #129	同主题不同实体 (NAR=1.0)	CoT 排除「进决赛非夺冠」
RGB #42	「首日冠军」被「日冠军」劫持	CoT 拆解时间限定词
MobileMem #370093	2 positive 仍在但答无关商品	CoT 重建 Q2 过滤 + 最小价
BRIGHT #302	长文 hard neg 后 naive 合成放弃	CoT 跨文档归纳 Doc3/Doc9

BRIGHT #302 (economics, $r = 0.75$): clean 下 10/10 positive, naive 正确综合「外债相对内债更危险」; 注入 8 篇 hard negative 后仅余 2 篇 positive, naive 输出「文档不足以支持比较」(Judge=0.6), confidence 经 Step1-2 映射 Doc3 (国内债与反通胀偏误)、Doc9 (违约范围差异) 后给出有节制机制归纳 (Judge=1.0)。BRIGHT smoke ($n = 5$) 聚合: naive Judge 0.92 $\rightarrow$ 0.84, confidence 1.0 $\rightarrow$ 0.88, CRR=0.5。

5.13 实验结论

RGB 中期实验揭示 U 型抗噪与互锁效应; 后期 2Wiki/MobileMem/Cmedqa 验证可迁移性——2Wiki $r = 0.75$ confidence F1 0.577 vs naive 0.422; MobileMem confidence Judge 0.536 vs 0.440; Cmedqa CRR=5.17。自适应矫正器在 counterfactual 场景等于 prompt 最优并避开 CoT 崩溃。

6 方法局限性讨论

表 22: 本工作方法 with 现有方法的比较

维度	Self-RAG (2024)	CRAG (2024)	本工作
核心机制	反思 token 门控	分解-重组流水线	证据链 + 多 Persona+ 自适应路由
噪音感知	隐式 (相关判定)	隐式	显式 (噪音类型检测 + 路由)
评估粒度	端到端指标	端到端指标	端到端 +ISR/NAR+ 语义级溯源
噪音类型适配	单一策略	单一策略	互锁效应驱动的类型自适应
API 成本	高 ($n+2$)	中	低-中 (1-4), 自适应仅 +1
中文评测	无系统评测	无系统评测	RGB zh 完整评测

创新点总结:

1. 发现了“互锁效应”——最优矫正方法取决于噪音类型, CoT 证据链在语义噪音下最优但在反事实噪音下反而有害;
2. 提出并验证了自适应矫正器, 利用噪音类型检测实现方法路由;
3. 提出语义级 ISR/NAR, 将 token 重叠升级为 LLM 驱动的信息归属判定;
4. 发现了在高强度反事实噪音下的位置效应, back 位置最差, interleave 最优;
5. 提供了中英文跨语言 RAG 鲁棒性基准;
6. 构建了自动化数据引擎, 从维基百科爬取真实文档并用 LLM 生成高质量 RAG 测试数据, 支持按需扩展 benchmark。

6.1 方法边界与不足

- $r = 1.0$ 时 positive 消失, 矫正多数失效;
- counterfactual 互锁: CoT 可能强化假证据, 需 adaptive/prompt;
- 依赖 4B 本地模型与 Judge 主观性; RGB 曲线对强模型偏平坦;
- BRIGHT 长文需 prompt 截断; 部分扩展数据集仅 smoke 验证。